

Resum

Aquest treball presenta el disseny i desenvolupament d'una base de dades estructurada per a descriure l'activitat investigadora de l'Institut Universitari de Matemàtica Pura i Aplicada (IUMPA). A partir d'informació procedent de diferents fonts públiques, es va construir un sistema organitzat que permet representar investigadors, publicacions, revistes, projectes i relacions de col·laboració entre ells. El procés va requerir tasques de recopilació, depuració, homogeneïtzació i validació de dades, així com el disseny d'estructures intermèdies que permeteren transformar informació dispersa en un conjunt de dades coherent i explotable.

Sobre aquesta base, es va desenvolupar una aplicació interactiva en R mitjançant la llibreria Shiny, en la qual s'integren diferents grafs que permeten explorar visualment les relacions entre investigadors, les seues publicacions i els projectes en els quals participen. L'objectiu d'esta plataforma és facilitar la consulta i l'anàlisi de l'estructura investigadora de l'institut d'una manera accessible i intuïtiva.

Com a ampliació analítica, es va abordar l'estudi d'afinitats temàtiques entre investigadors a partir de les revistes en les quals han publicat. Per a això es van extraure paraules clau representatives, es van construir matrius de dades específiques i es van avaluar diferents estratègies d'agrupació. Després de comprovar les limitacions dels enfocaments basats en coincidències literals de paraules, es va adoptar una representació semàntica mitjançant "word embeddings", sobre la qual es van aplicar tècniques de clustering jeràrquic i reducció de dimensionalitat, amb l'objectiu d'identificar perfils investigadors similars que puguen afavorir la col·laboració i el treball en equip entre investigadors amb nuclis temàtics afins. Els resultats obtinguts permeten complementar la visió relacional dels grafs amb una aproximació temàtica a l'activitat investigadora de l'IUMPA.

Tot plegat, el treball ofereix un marc general per comprendre millor l'estructura investigadora de l'institut, a més d'establir una base per a futures ampliacions d'anàlisi i visualització.

Paraules clau: IUMPA, bases de dades, visualització, grafs, aprenentatge automàtic, agrupació semàntica

Resumen

Este trabajo presenta el diseño y desarrollo de una base de datos estructurada para describir la actividad investigadora del Instituto Universitario de Matemática Pura y Aplicada (IUMPA). A partir de información procedente de distintas fuentes públicas, se construyó un sistema organizado que permite representar investigadores, publicaciones, revistas, proyectos y relaciones de colaboración entre ellos. El proceso requirió tareas de recopilación, depuración, homogeneización y validación de datos, así como el diseño de estructuras intermedias que permitieran transformar información dispersa en un conjunto de datos coherente y explotable.

Sobre esta base, se desarrolló una aplicación interactiva en R mediante la librería Shiny, en la que se integran diferentes grafos que permiten explorar visualmente las relaciones entre investigadores, sus publicaciones y los proyectos en los que participan. El objetivo de esta plataforma es facilitar la consulta y el análisis de la estructura investigadora del instituto de una forma accesible e intuitiva.

Como ampliación analítica, se abordó el estudio de afinidades temáticas entre investigadores a partir de las revistas en las que han publicado. Para ello se extrajeron palabras

clave representativas, se construyeron matrices de datos específicas y se evaluaron distintas estrategias de agrupación. Tras comprobar las limitaciones de los enfoques basados en coincidencias literales de palabras, se adoptó una representación semántica mediante "word embeddings", sobre la que se aplicaron técnicas de clustering jerárquico y reducción de dimensionalidad, con el objetivo de identificar perfiles investigadores similares que puedan facilitar la colaboración y el trabajo en equipo entre investigadores con núcleos temáticos afines. Los resultados obtenidos permiten complementar la visión relacional de los grafos con una aproximación temática a la actividad investigadora del IUMPA.

En conjunto, el trabajo ofrece un marco general para comprender mejor la estructura investigadora del instituto, además de establecer una base para futuras ampliaciones de análisis y visualización.

Palabras clave: IUMPA, base de datos, visualización, grafos, aprendizaje automático, agrupación semántica

Abstract

This thesis presents the design and development of a structured database to describe the research activity of the Instituto Universitario de Matemática Pura y Aplicada (IUMPA). Using information collected from several public sources, an organized system was built to represent researchers, publications, journals, projects, and collaboration links among them. The process required data collection, cleaning, homogenization, and validation tasks, as well as the design of intermediate data structures to transform scattered information into a coherent and usable dataset.

Based on this dataset, an interactive application was developed in R using the Shiny library. The application integrates several graphs that allow visual exploration of the relationships between researchers, their publications, and the projects in which they participate. The objective of this platform is to make it possible to consult and analyze the institute's research structure in an accessible and intuitive way.

As an analytical extension, thematic affinities among researchers were studied using the journals in which they had published. To achieve this, representative keywords were extracted, specific data matrices were built, and different clustering strategies were evaluated. After observing the limitations of approaches based on literal keyword matching, a semantic representation based on word embeddings was adopted, and hierarchical clustering and dimensionality reduction techniques were applied, with the aim of identifying similar research profiles that may support collaboration and teamwork among researchers with related thematic areas. The obtained results complement the relational view provided by the graphs with a thematic perspective on IUMPA's research activity.

Overall, this work provides a general framework for better understanding the institute's research structure and establishes a basis for future extensions in both analysis and visualization.

Key words: IUMPA, database, visualization, graphs, machine learning, semantic clustering

Índice general

Índice general	v
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Alcance del trabajo	2
1.4 Estructura de la memoria	2
2 Contexto del problema y estado del arte	5
2.1 Información investigadora y análisis de la actividad científica	5
2.2 Representación y visualización de relaciones científicas	6
2.3 Agrupación temática de perfiles investigadores	7
3 Diseño conceptual y planificación del proyecto	9
3.1 Planteamiento inicial del modelo	9
3.2 Evolución del diseño, limitaciones y decisiones adoptadas	9
3.3 Planificación del trabajo	10
4 Construcción de la base de datos	11
4.1 Fuentes de datos	11
4.2 Extracción y organización inicial de la información	11
4.3 Depuración, homogeneización y validación de los datos	11
4.4 Estructura final de las bases de datos	12
4.5 Valoración de la base de datos construida	12
5 Desarrollo de la aplicación interactiva	13
5.1 Diseño general de la herramienta	13
5.2 Construcción de los grafos interactivos	13
5.3 Elementos de interacción y visualización	13
5.4 Valoración de la aplicación desarrollada	14
6 Agrupación semántica de investigadores	15
6.1 Construcción de palabras clave	15
6.2 Representación temática de los investigadores	15
6.3 Modelos de clustering	15
6.4 Evaluación y discusión de los resultados	16
7 Conclusiones y trabajo futuro	17
7.1 Conclusiones generales	17
7.2 Cumplimiento de los objetivos	17
7.3 Líneas de trabajo futuro	17
Bibliografía	19
Apéndices	
A Relación del trabajo con los Objetivos de Desarrollo Sostenible	21
B Material complementario	23

CAPÍTULO 1

Introducción

El presente Trabajo Fin de Grado se enmarca en el ámbito del análisis de datos, la estructuración de información investigadora y su posterior explotación mediante técnicas de visualización y agrupación semántica. El proyecto se centra en el Instituto Universitario de Matemática Pura y Aplicada (IUMPA), con el objetivo de organizar información relativa a sus investigadores, publicaciones, revistas, proyectos y relaciones de colaboración.

A partir de esta información, se plantea una solución que combina tres componentes principales: la construcción de una base de datos estructurada, el desarrollo de una aplicación interactiva para la visualización de relaciones mediante grafos y la aplicación de técnicas de agrupación semántica para analizar afinidades temáticas entre investigadores. De este modo, el proyecto aborda tareas de recopilación, limpieza, integración, modelado, visualización e interpretación de datos.

1.1 Motivación

En un entorno académico e investigador, gran parte de la información relevante sobre los miembros de un instituto se encuentra repartida entre directorios web, plataformas bibliográficas, bases de datos institucionales y otras fuentes externas. Aunque cada una de estas fuentes aporta información útil, la falta de uniformidad entre ellas dificulta su explotación conjunta y complica la obtención de una visión global del instituto.

En el caso del IUMPA, resultaba de especial interés disponer de una base de datos organizada y de una herramienta que permitiese analizar tanto las relaciones entre investigadores como sus publicaciones, revistas y proyectos asociados. A partir de esta necesidad, el trabajo se planteó como una oportunidad para aplicar conocimientos de ciencia de datos a un caso real, abordando un problema de recopilación, integración, modelado, visualización y análisis temático de la información.

1.2 Objetivos

El objetivo principal de este trabajo es diseñar una base de datos estructurada de la actividad investigadora del IUMPA y desarrollar herramientas que permitan analizarla y visualizarla de forma comprensible.

De forma más específica, los objetivos perseguidos son los siguientes:

- Identificar las entidades y relaciones relevantes para describir la actividad investigadora del instituto.

- Recopilar información procedente de distintas fuentes públicas y transformarla en bases de datos organizadas y coherentes.
- Resolver problemas de calidad de datos, duplicidad, formatos heterogéneos e información incompleta.
- Desarrollar una aplicación interactiva en R y Shiny que permita explorar visualmente la información mediante grafos.
- Analizar afinidades temáticas entre investigadores a partir de sus publicaciones y de las revistas en las que publican.
- Evaluar distintas estrategias de agrupación hasta obtener una representación temática suficientemente interpretable.

1.3 Alcance del trabajo

El alcance de este trabajo comprende el diseño y desarrollo de una base de datos orientada a representar la actividad investigadora del IUMPA a partir de información procedente de fuentes públicas y accesibles. En concreto, el proyecto se centra en recopilar, tratar y estructurar datos relacionados con los investigadores del instituto, así como de su actividad investigadora (publicaciones, revistas y proyectos) y de sus relaciones de colaboración. Esta base de datos final se explota mediante herramientas de visualización y análisis.

El trabajo incluye el desarrollo de una aplicación interactiva en R mediante Shiny, destinada a facilitar la exploración visual de la información mediante grafos. Estos grafos permiten representar distintas relaciones entre los elementos del sistema, como colaboraciones entre investigadores, publicaciones en revistas y participación en proyectos. Además, se incorpora una ampliación analítica basada en la extracción de palabras clave y en la aplicación de técnicas de agrupación semántica, con el objetivo de identificar afinidades temáticas entre investigadores.

El sistema desarrollado debe entenderse como una herramienta exploratoria y analítica orientada a facilitar la comprensión de la actividad investigadora del instituto. Por tanto, su finalidad no es establecer clasificaciones personales ni métricas comparativas de productividad entre investigadores, sino proporcionar una base estructurada que permita consultar y analizar la información recopilada desde una perspectiva relacional y temática. Asimismo, el alcance del proyecto queda condicionado por la disponibilidad, calidad y homogeneidad de la información accesible en las fuentes consultadas.

1.4 Estructura de la memoria

La memoria se organiza en varios capítulos. En primer lugar, se introduce el problema abordado, la motivación del trabajo, los objetivos perseguidos y el alcance general del proyecto. A continuación, se presenta el contexto del problema y el estado del arte relacionado con la representación de información investigadora, la integración de información procedente de fuentes heterogéneas, las técnicas de visualización y los métodos de agrupación empleados.

Después, se describe el diseño conceptual del sistema, la evolución del modelo inicial y las principales decisiones adoptadas durante el desarrollo del proyecto. Posteriormente, se detalla el proceso de construcción de la base de datos, incluyendo la recopilación, limpieza y homogeneización de la información. A continuación, se presenta el desarrollo de

la aplicación interactiva en Shiny y la construcción de los diferentes grafos definidos para representar la actividad investigadora del instituto.

Más adelante, se expone la ampliación analítica del trabajo, centrada en la extracción de palabras clave y en la agrupación semántica de investigadores mediante distintas metodologías. Finalmente, se sintetizan los resultados obtenidos y se recogen las conclusiones principales del proyecto, sus limitaciones y las posibles líneas de trabajo futuro.

CAPÍTULO 2

Contexto del problema y estado del arte

El análisis de la actividad investigadora requiere organizar información procedente de fuentes diversas y, con frecuencia, heterogéneas. Esta información suele encontrarse dispersa en plataformas bibliográficas, directorios institucionales y otras fuentes externas, lo que dificulta su consulta conjunta y limita la obtención de una visión global de la estructura científica de una institución. Por ello, resulta necesario definir modelos que permitan integrarla, relacionarla y explotarla de forma coherente.

Una vez estructurados los datos, su utilidad depende en gran medida de la forma en que puedan ser consultados e interpretados. Las tablas permiten almacenar la información de manera ordenada, pero no siempre facilitan la comprensión de las relaciones existentes entre los distintos elementos del sistema. En este sentido, los grafos constituyen una herramienta especialmente adecuada para representar vínculos, como la colaboración o la publicación, mientras que las aplicaciones interactivas permiten explorar dichas relaciones de forma más flexible y comprensible.

Además de representar relaciones explícitas, como colaboraciones o participaciones comunes, también puede resultar útil analizar similitudes menos directas entre perfiles investigadores. Dos investigadores pueden estar próximos no solo porque hayan trabajado juntos, sino también porque desarrollen su actividad en ámbitos temáticos relacionados. Por este motivo, las técnicas de agrupación y las representaciones semánticas ofrecen una perspectiva complementaria, orientada a identificar afinidades temáticas a partir de la información disponible sobre la producción científica.

2.1 Información investigadora y análisis de la actividad científica

El análisis de la actividad científica de una institución requiere transformar información dispersa en una representación organizada y comprensible. La actividad investigadora no se refleja únicamente en los resultados finales, sino también en el contexto en el que estos se generan y en las relaciones que se establecen alrededor de ellos.

Desde esta perspectiva, la información bibliográfica e institucional constituye una base fundamental para estudiar la estructura científica de un centro. Más allá del valor particular de cada registro, su interés aumenta cuando los datos pueden relacionarse entre sí para describir distintas dimensiones de la actividad investigadora, como la producción científica, la colaboración entre miembros de la comunidad académica o la orientación temática de sus trabajos.

Este análisis se relaciona con enfoques propios de la bibliometría y del estudio de la actividad científica, que utilizan datos académicos para caracterizar la estructura investigadora de instituciones y comunidades. Esta visión conjunta permite identificar conexiones, patrones de colaboración y posibles afinidades temáticas que no serían evidentes a partir de elementos aislados.

Sin embargo, este tipo de información suele presentar dificultades importantes desde el punto de vista del tratamiento de datos. Es habitual que proceda de fuentes distintas, con formatos heterogéneos, criterios de identificación no siempre uniformes y distintos niveles de completitud. Por ello, antes de poder realizar cualquier análisis, resulta necesario recopilar, depurar y homogeneizar los datos, de forma que puedan analizarse de manera coherente.

La organización de esta información permite pasar de una colección de registros independientes a un sistema de datos explotable. Esta transformación facilita la consulta, mejora la trazabilidad de las relaciones entre elementos y proporciona una base adecuada para aplicar técnicas posteriores de visualización y análisis. En este sentido, la construcción de una base de datos no debe entenderse únicamente como una fase previa del proyecto, sino como un elemento central para poder representar y analizar de forma coherente la actividad investigadora.

2.2 Representación y visualización de relaciones científicas

Una vez organizada la información investigadora, una parte importante del análisis consiste en representar los vínculos que estructuran el sistema. En este tipo de contexto, no solo interesa consultar registros individuales, sino también comprender cómo se relacionan entre sí. Las colaboraciones entre investigadores, la participación en proyectos o la relación entre publicaciones y revistas son ejemplos de vínculos que pueden aportar información relevante sobre la estructura científica de una institución.

Los grafos constituyen una forma adecuada de modelar este tipo de relaciones, ya que permiten representar sistemas formados por entidades conectadas entre sí [1]. En ellos, los nodos representan las entidades del sistema y las aristas indican los vínculos existentes entre ellas. Esta representación permite pasar de una visión tabular, centrada en registros independientes, a una visión relacional, en la que las conexiones entre elementos ayudan a interpretar la estructura global de los datos. De este modo, los grafos facilitan la identificación de patrones de colaboración, elementos especialmente conectados o agrupaciones de entidades relacionadas.

Cuando el número de elementos y relaciones aumenta, la representación visual debe complementarse con mecanismos que faciliten la exploración de la información. La interactividad permite seleccionar elementos concretos, aplicar filtros, consultar información asociada y adaptar la visualización a distintas preguntas de análisis. Así, el usuario puede explorar la red de forma progresiva, pasando de una visión general del sistema a detalles específicos sobre determinados nodos o relaciones.

Herramientas como Shiny permiten construir aplicaciones web orientadas a la exploración de datos, mientras que librerías de visualización como ECharts facilitan la creación de grafos dinámicos e interactivos. Su uso permite transformar una representación estática de la información en un entorno de consulta más accesible.

2.3 Agrupación temática de perfiles investigadores

Las relaciones explícitas, como las colaboraciones entre autores, permiten describir una parte importante de la actividad investigadora, pero no siempre reflejan todas las proximidades existentes entre perfiles. También pueden existir afinidades temáticas entre investigadores que trabajan en ámbitos relacionados, aunque no hayan colaborado directamente, por lo que resulta útil complementar el análisis relacional con técnicas de agrupación temática.

Esta perspectiva permite comparar perfiles investigadores a partir de los temas asociados a su producción científica. Para ello, pueden emplearse elementos textuales o descriptivos relacionados con las publicaciones, las revistas o los términos que caracterizan dichas fuentes, con el fin de construir una representación que recoja los intereses principales de cada investigador. Este planteamiento se relaciona con enfoques habituales de recuperación de información y representación textual, donde los documentos o términos se transforman en estructuras comparables para poder analizar su similitud [2]. A partir de estas representaciones, es posible estudiar qué perfiles presentan mayor proximidad temática y qué grupos comparten características similares.

Las técnicas de agrupación permiten organizar estos perfiles en conjuntos de elementos similares sin necesidad de definir previamente una clasificación cerrada, por lo que se enmarcan dentro de los métodos de aprendizaje no supervisado [3]. En este contexto, el clustering resulta útil para explorar si existen patrones latentes en los datos y para identificar posibles grupos de investigadores con afinidades comunes. No obstante, la calidad de estas agrupaciones depende en gran medida de cómo se represente la información de partida, especialmente cuando se trabaja con datos textuales o temáticos.

Por este motivo, las representaciones semánticas, como los *word embeddings*, ofrecen una alternativa más rica que la comparación literal de palabras. Estos modelos permiten representar términos en espacios vectoriales continuos, de forma que la proximidad entre vectores puede reflejar relaciones de similitud sintáctica o semántica [4]. Mientras que los enfoques basados únicamente en coincidencias exactas pueden no detectar relaciones entre términos distintos pero conceptualmente próximos, los embeddings permiten incorporar información semántica a la comparación entre perfiles. De esta forma, es posible comparar perfiles investigadores no solo por las palabras concretas asociadas a ellos, sino también por la cercanía conceptual entre sus temas de trabajo.

La agrupación temática proporciona así una visión complementaria a la obtenida mediante grafos de colaboración o participación. Mientras que la representación relacional muestra conexiones explícitas, el análisis semántico permite explorar afinidades menos evidentes y enriquecer la comprensión de la estructura científica de una institución.

CAPÍTULO 3

Diseño conceptual y planificación del proyecto

Este capítulo describe el planteamiento inicial y el diseño conceptual del proyecto. Para ello, se presentan las entidades, relaciones y propiedades consideradas inicialmente, así como los criterios seguidos para estructurar la información y transformar el problema en un modelo de datos coherente.

Además, se explica cómo evolucionó dicho modelo al contrastarlo con la disponibilidad real de información, qué decisiones de diseño se adoptaron y qué elementos fueron modificados o descartados durante las primeras fases del trabajo. Finalmente, se recogen las principales limitaciones y consideraciones metodológicas, éticas y de reproducibilidad asociadas al proyecto, junto con la planificación general seguida para su desarrollo.

3.1 Planteamiento inicial del modelo

Este apartado describirá el modelo conceptual planteado al inicio del proyecto para representar la actividad investigadora del IUMPA. Se presentarán las entidades consideradas relevantes, como investigadores, revistas, áreas, publicaciones y proyectos, así como las relaciones previstas entre ellas. También se explicará qué tipo de información se pretendía recoger para cada elemento y cómo este planteamiento inicial servía como punto de partida para organizar los datos de forma estructurada.

3.2 Evolución del diseño, limitaciones y decisiones adoptadas

Este apartado explicará cómo evolucionó el diseño inicial al contrastarlo con la disponibilidad, calidad y homogeneidad de la información accesible. Se describirán las principales decisiones adoptadas durante el desarrollo del proyecto, incluyendo los elementos que fueron modificados, simplificados o descartados por falta de datos fiables, por redundancia con otras variables o por no aportar suficiente valor al objetivo final del trabajo.

También se recogerán las principales limitaciones y consideraciones metodológicas, éticas y de reproducibilidad asociadas a estas decisiones. Se aclarará que el sistema se apoya en información pública y accesible, que su finalidad es exploratoria y analítica, no evaluativa, y que no pretende establecer clasificaciones personales ni métricas comparativas de productividad. Asimismo, se indicará qué partes del proceso pueden reproducirse mediante código y qué decisiones requirieron intervención manual o validación específica.

3.3 Planificación del trabajo

Este apartado describirá la organización general seguida durante el desarrollo del proyecto. Se presentarán las principales fases del trabajo, desde la definición inicial del modelo y la búsqueda de fuentes de información hasta la construcción de la base de datos, el desarrollo de la aplicación interactiva, la ampliación analítica mediante agrupación semántica y la interpretación de resultados. Esta planificación permitirá mostrar la evolución del TFG y conectar las decisiones de diseño con las etapas posteriores de implementación y análisis.

CAPÍTULO 4

Construcción de la base de datos

Este capítulo describirá el proceso seguido para construir la base de datos del proyecto a partir de información procedente de distintas fuentes públicas. Se presentarán las fuentes finalmente utilizadas, el procedimiento de extracción y organización inicial de la información, las tareas de depuración, homogeneización y validación realizadas, y la estructura final de las bases de datos empleadas posteriormente en la aplicación interactiva y en el análisis semántico.

4.1 Fuentes de datos

Este apartado describirá las fuentes finalmente utilizadas para recopilar la información del proyecto, como la web del IUMPA, Google Scholar, Scopus, ORCID, Panorama UPV y otras fuentes auxiliares empleadas para completar o contrastar datos. Se explicará qué tipo de información aportó cada fuente, qué papel tuvo dentro del proyecto y qué limitaciones generales presentaba en relación con la disponibilidad, completitud y fiabilidad de los datos.

4.2 Extracción y organización inicial de la información

Este apartado explicará cómo se obtuvo y organizó inicialmente la información procedente de las distintas fuentes. Se describirán los procedimientos empleados, como la recopilación manual, el uso de técnicas de web scraping, la descarga de ficheros o la consulta de plataformas externas, así como la creación de estructuras intermedias para almacenar los datos en formato tabular. El objetivo será mostrar cómo la información dispersa se transformó en un conjunto inicial de datos manejable y preparado para su posterior depuración.

4.3 Depuración, homogeneización y validación de los datos

Este apartado describirá las tareas realizadas para mejorar la calidad y coherencia de la información recopilada. Se tratarán aspectos como la corrección de errores tipográficos, el tratamiento de codificaciones, la homogeneización de nombres de investigadores, firmas y revistas, la resolución de duplicidades, la eliminación de registros erróneos o no relevantes y la validación manual de casos ambiguos. Esta sección permitirá justificar el esfuerzo necesario para convertir datos heterogéneos en una base fiable y explotable.

4.4 Estructura final de las bases de datos

Este apartado presentará la estructura definitiva de las bases de datos construidas durante el proyecto. Se describirán las entidades y relaciones finalmente representadas, los principales ficheros generados, las variables incluidas y la forma en que estas estructuras permiten alimentar tanto la aplicación interactiva como la fase posterior de agrupación semántica. También se señalarán, cuando sea necesario, las diferencias entre el modelo inicialmente planteado y la estructura final obtenida.

4.5 Valoración de la base de datos construida

Este apartado valorará el resultado obtenido tras el proceso de construcción de la base de datos. Se analizará en qué medida la estructura final permite representar de forma coherente la actividad investigadora del IUMPA, qué entidades y relaciones quedan cubiertas y qué utilidad tiene la base como soporte para las fases posteriores del proyecto. También se comentará, de forma sintética, cómo las limitaciones de disponibilidad, calidad y homogeneidad de la información condicionan la interpretación y el uso de la base de datos resultante.

CAPÍTULO 5

Desarrollo de la aplicación interactiva

Este capítulo describirá el desarrollo de la aplicación interactiva construida en R mediante Shiny para explorar la información almacenada en la base de datos. Se explicará la organización general de la herramienta, el proceso de transformación de los datos en grafos interactivos y los elementos de visualización e interacción incorporados para facilitar la consulta de relaciones entre investigadores, publicaciones, revistas y proyectos.

5.1 Diseño general de la herramienta

Este apartado presentará la arquitectura general de la aplicación desarrollada en Shiny. Se explicará cómo se organiza la herramienta, qué papel desempeñan los datos previamente construidos y cómo se estructura la aplicación para permitir la consulta interactiva de la información. También se describirá, de forma general, la relación entre la base de datos, la lógica de procesamiento y los componentes visuales que se muestran al usuario.

5.2 Construcción de los grafos interactivos

Este apartado describirá los diferentes grafos desarrollados para representar la actividad investigadora del IUMPA. Se explicará qué relaciones muestra cada grafo, qué entidades actúan como nodos, qué conexiones se representan mediante aristas y cómo se transforman las bases de datos en estructuras adecuadas para su visualización. También se detallará el papel de los grafos de investigadores, publicaciones, revistas y proyectos dentro de la aplicación.

5.3 Elementos de interacción y visualización

Este apartado recogerá los elementos incorporados para facilitar la exploración de los grafos, como selectores, filtros, paneles informativos, colores, tamaños de nodos y respuestas ante la interacción del usuario. Se explicarán las decisiones de diseño adoptadas para mejorar la legibilidad de las visualizaciones y permitir que el usuario consulte la información de forma intuitiva, dejando la valoración global de la herramienta para el apartado siguiente.

5.4 Valoración de la aplicación desarrollada

Este apartado valorará la utilidad de la aplicación interactiva desarrollada para explorar la información almacenada en la base de datos. Se discutirá en qué medida los grafos permiten representar de forma comprensible las relaciones entre investigadores, publicaciones, revistas y proyectos, y qué aportan los elementos de interacción incorporados frente a una consulta basada únicamente en tablas o ficheros estáticos. También se señalarán las principales limitaciones visuales o funcionales detectadas y posibles mejoras de la herramienta.

CAPÍTULO 6

Agrupación semántica de investigadores

Este capítulo describirá la ampliación analítica del proyecto, orientada a estudiar afinidades temáticas entre investigadores a partir de las revistas en las que han publicado. Para ello, se explicará el proceso de obtención de palabras clave representativas, la construcción de representaciones temáticas de los investigadores y la aplicación de distintos modelos de clustering y reducción de dimensionalidad. El objetivo será mostrar el proceso metodológico seguido hasta obtener una agrupación semántica interpretable.

6.1 Construcción de palabras clave

Este apartado explicará el proceso seguido para obtener palabras clave representativas de las revistas en las que han publicado los investigadores del IUMPA. Se describirá cómo se recopilaron, revisaron y filtraron dichos términos, así como los criterios utilizados para conservar aquellos que resultaban útiles para caracterizar temáticamente las revistas. Esta sección permitirá justificar la base textual sobre la que se construye posteriormente la representación temática de cada investigador.

6.2 Representación temática de los investigadores

Este apartado describirá cómo se transformaron las palabras clave asociadas a las revistas en representaciones analizables de los investigadores. Se explicará la construcción de matrices que relacionan investigadores, revistas y términos temáticos, así como los primeros enfoques basados en coincidencias literales de palabras clave. También se introducirá el cambio hacia representaciones semánticas mediante embeddings, justificando su utilidad para capturar similitudes conceptuales entre perfiles aunque no compartan exactamente los mismos términos.

6.3 Modelos de clustering

Este apartado presentará los distintos modelos de agrupación aplicados sobre las representaciones temáticas construidas. Se describirán las pruebas realizadas con diferentes medidas de distancia, métodos de clustering y técnicas de reducción de dimensionalidad, así como los criterios utilizados para comparar sus resultados. El apartado también recogerá

las dificultades encontradas durante el proceso experimental y las decisiones metodológicas adoptadas para seleccionar las configuraciones más adecuadas.

6.4 Evaluación y discusión de los resultados

Este apartado evaluará los resultados obtenidos en la fase de agrupación semántica de investigadores. Se analizarán las diferencias entre los enfoques probados, la utilidad de las representaciones semánticas frente a las coincidencias literales de palabras clave y la calidad de las agrupaciones obtenidas a partir de métricas cuantitativas y criterios de coherencia temática. También se discutirá hasta qué punto estos resultados complementan la información relacional proporcionada por los grafos y qué limitaciones deben tenerse en cuenta al interpretar los grupos identificados.

CAPÍTULO 7

Conclusiones y trabajo futuro

Este capítulo recogerá las conclusiones generales del trabajo a partir del desarrollo y las valoraciones realizadas en los capítulos anteriores. Se sintetizarán los principales resultados alcanzados en relación con la construcción de la base de datos, el desarrollo de la aplicación interactiva y la agrupación semántica de investigadores, evitando introducir información nueva que no haya sido discutida previamente.

También se valorará el grado de cumplimiento de los objetivos planteados al inicio del trabajo y se destacarán las principales aportaciones del proyecto desde el punto de vista de la ciencia de datos. Finalmente, se señalarán las limitaciones generales que permanecen y se propondrán posibles líneas de trabajo futuro, como la ampliación o actualización de las fuentes de datos, la mejora de la aplicación interactiva y la extensión de la parte analítica.

7.1 Conclusiones generales

Este apartado sintetizará las conclusiones principales del trabajo a partir de los resultados y valoraciones expuestos en los capítulos anteriores. Se recogerá de forma global qué ha aportado la construcción de la base de datos, qué utilidad tiene la aplicación interactiva desarrollada y qué valor añade la agrupación semántica de investigadores. El objetivo será ofrecer una visión conjunta del proyecto, destacando su contribución a la comprensión de la actividad investigadora del IUMPA sin introducir resultados nuevos.

7.2 Cumplimiento de los objetivos

Este apartado revisará los objetivos planteados al inicio de la memoria y valorará en qué medida han sido alcanzados. Se relacionarán los objetivos específicos con las fases desarrolladas durante el proyecto: identificación de entidades y relaciones, recopilación y depuración de datos, construcción de la base de datos, desarrollo de la aplicación interactiva y análisis de afinidades temáticas. Esta sección permitirá cerrar el trabajo de forma coherente, conectando lo propuesto en la introducción con los resultados obtenidos.

7.3 Líneas de trabajo futuro

Este apartado planteará posibles ampliaciones y mejoras del proyecto. Se incluirán líneas como la incorporación de nuevas fuentes de datos, la actualización periódica de la base, la mejora de la aplicación interactiva, la ampliación de las funcionalidades de visualización y el perfeccionamiento de la parte analítica. También se podrán mencionar

posibles extensiones metodológicas, como nuevas formas de representación semántica, métricas adicionales o procedimientos más automatizados de validación y actualización de datos.

Bibliografía

- [1] Newman, M. E. J. *Networks: An Introduction*. Oxford University Press, 2010.
- [2] Manning, C. D., Raghavan, P. y Schütze, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [3] Hastie, T., Tibshirani, R. y Friedman, J. *The Elements of Statistical Learning*. Springer, 2009.
- [4] Mikolov, T., Chen, K., Corrado, G. y Dean, J. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*, 2013.

APÉNDICE A

Relación del trabajo con los Objetivos de Desarrollo Sostenible

Este anexo recogerá la relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS), de acuerdo con las directrices establecidas por la ETSINF para los Trabajos Fin de Grado. En la versión final de la memoria, aquí deberá incorporarse la justificación de los ODS con los que el proyecto guarda una relación más directa, explicando de qué manera contribuye a ellos y cuál es el alcance real de dicha contribución.

APÉNDICE B

Material complementario

En este anexo podrán incluirse tablas extensas, esquemas auxiliares, detalles técnicos adicionales, capturas ampliadas de la aplicación o cualquier otro material complementario que ayude a entender mejor el trabajo sin sobrecargar el cuerpo principal de la memoria.