

Resum

Aquest treball presenta el disseny i desenvolupament d'una base de dades estructurada per a descriure l'activitat investigadora de l'Institut Universitari de Matemàtica Pura i Aplicada (IUMPA). A partir d'informació procedent de diferents fonts públiques, es va construir un sistema organitzat que permet representar investigadors, publicacions, revistes, projectes i relacions de col·laboració entre ells. El procés va requerir tasques de recopilació, depuració, homogeneïtzació i validació de dades, així com el disseny d'estructures intermèdies que permeten transformar informació dispersa en un conjunt de dades coherent i explotable.

Sobre aquesta base, es va desenvolupar una aplicació interactiva en R mitjançant la llibreria Shiny, en la qual s'integren diferents grafs que permeten explorar visualment les relacions entre investigadors, les seues publicacions i els projectes en els quals participen. L'objectiu d'esta plataforma és facilitar la consulta i l'anàlisi de l'estructura investigadora de l'institut d'una manera accessible i intuïtiva.

Com a ampliació analítica, es va abordar l'estudi d'afinitats temàtiques entre investigadors a partir de les revistes en les quals han publicat. Per a això es van extraure paraules clau representatives, es van construir matrius de dades específiques i es van avaluar diferents estratègies d'agrupació. Després de comprovar les limitacions dels enfocaments basats en coincidències literals de paraules, es va adoptar una representació semàntica mitjançant "word embeddings", sobre la qual es van aplicar tècniques de clustering jeràrquic i reducció de dimensionalitat, amb l'objectiu d'identificar perfils investigadors similars que puguen afavorir la col·laboració i el treball en equip entre investigadors amb nuclis temàtics afins. Els resultats obtinguts permeten complementar la visió relacional dels grafs amb una aproximació temàtica a l'activitat investigadora de l'IUMPA.

Tot plegat, el treball ofereix un marc general per comprendre millor l'estructura investigadora de l'institut, a més d'establir una base per a futures ampliacions d'anàlisi i visualització.

Paraules clau: IUMPA, bases de dades, visualització, grafs, aprenentatge automàtic, agrupació semàntica

Resumen

Este trabajo presenta el diseño y desarrollo de una base de datos estructurada para describir la actividad investigadora del Instituto Universitario de Matemática Pura y Aplicada (IUMPA). A partir de información procedente de distintas fuentes públicas, se construyó un sistema organizado que permite representar investigadores, publicaciones, revistas, proyectos y relaciones de colaboración entre ellos. El proceso requirió tareas de recopilación, depuración, homogeneización y validación de datos, así como el diseño de estructuras intermedias que permitieran transformar información dispersa en un conjunto de datos coherente y explotable.

Sobre esta base, se desarrolló una aplicación interactiva en R mediante la librería Shiny, en la que se integran diferentes grafos que permiten explorar visualmente las relaciones entre investigadores, sus publicaciones y los proyectos en los que participan. El objetivo de esta plataforma es facilitar la consulta y el análisis de la estructura investigadora del instituto de una forma accesible e intuitiva.

Como ampliación analítica, se abordó el estudio de afinidades temáticas entre investigadores a partir de las revistas en las que han publicado. Para ello se extrajeron palabras

clave representativas, se construyeron matrices de datos específicas y se evaluaron distintas estrategias de agrupación. Tras comprobar las limitaciones de los enfoques basados en coincidencias literales de palabras, se adoptó una representación semántica mediante "word embeddings", sobre la que se aplicaron técnicas de clustering jerárquico y reducción de dimensionalidad, con el objetivo de identificar perfiles investigadores similares que puedan facilitar la colaboración y el trabajo en equipo entre investigadores con núcleos temáticos afines. Los resultados obtenidos permiten complementar la visión relacional de los grafos con una aproximación temática a la actividad investigadora del IUMPA.

En conjunto, el trabajo ofrece un marco general para comprender mejor la estructura investigadora del instituto, además de establecer una base para futuras ampliaciones de análisis y visualización.

Palabras clave: IUMPA, base de datos, visualización, grafos, aprendizaje automático, agrupación semántica

Abstract

This thesis presents the design and development of a structured database to describe the research activity of the Instituto Universitario de Matemática Pura y Aplicada (IUMPA). Using information collected from several public sources, an organized system was built to represent researchers, publications, journals, projects, and collaboration links among them. The process required data collection, cleaning, homogenization, and validation tasks, as well as the design of intermediate data structures to transform scattered information into a coherent and usable dataset.

Based on this dataset, an interactive application was developed in R using the Shiny library. The application integrates several graphs that allow visual exploration of the relationships between researchers, their publications, and the projects in which they participate. The objective of this platform is to make it possible to consult and analyze the institute's research structure in an accessible and intuitive way.

As an analytical extension, thematic affinities among researchers were studied using the journals in which they had published. To achieve this, representative keywords were extracted, specific data matrices were built, and different clustering strategies were evaluated. After observing the limitations of approaches based on literal keyword matching, a semantic representation based on word embeddings was adopted, and hierarchical clustering and dimensionality reduction techniques were applied, with the aim of identifying similar research profiles that may support collaboration and teamwork among researchers with related thematic areas. The obtained results complement the relational view provided by the graphs with a thematic perspective on IUMPA's research activity.

Overall, this work provides a general framework for better understanding the institute's research structure and establishes a basis for future extensions in both analysis and visualization.

Key words: IUMPA, database, visualization, graphs, machine learning, semantic clustering

Índice general

Índice general	v
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Alcance del trabajo	2
1.4 Estructura de la memoria	2
2 Estado del arte y contexto del problema	5
2.1 Información investigadora y análisis de la actividad científica	5
2.2 Representación y visualización de relaciones científicas	5
2.3 Agrupación temática de perfiles investigadores	5
3 Diseño conceptual y planificación del proyecto	7
3.1 Planteamiento inicial del modelo	7
3.2 Evolución del diseño, limitaciones y decisiones adoptadas	7
3.3 Planificación del trabajo	8
4 Construcción de la base de datos	9
4.1 Fuentes de datos	9
4.2 Obtención y depuración de los datos	9
4.3 Estructura final de las bases de datos	9
5 Desarrollo de la aplicación interactiva	11
5.1 Diseño general de la herramienta	11
5.2 Grafos de investigadores, publicaciones y proyectos	11
5.3 Visualización, filtros e interpretación	11
6 Agrupación semántica de investigadores	13
6.1 Construcción de las palabras clave	13
6.2 Primeros enfoques de agrupación	13
6.3 Embeddings y clustering semántico	13
6.4 Interpretación de resultados	13
7 Resultados y discusión	15
8 Conclusiones y trabajo futuro	17
Bibliografía	19
Apéndices	
A Relación del trabajo con los Objetivos de Desarrollo Sostenible	21
B Material complementario	23

CAPÍTULO 1

Introducción

El presente Trabajo Fin de Grado se enmarca en el ámbito del análisis de datos, la estructuración de información investigadora y su posterior explotación mediante técnicas de visualización y agrupación semántica. El proyecto se centra en el Instituto Universitario de Matemática Pura y Aplicada (IUMPA), con el objetivo de organizar información relativa a sus investigadores, publicaciones, revistas, proyectos y relaciones de colaboración.

A partir de esta información, el trabajo plantea una solución que combina tres componentes principales: la construcción de una base de datos estructurada, el desarrollo de una aplicación interactiva para la visualización de relaciones mediante grafos y la aplicación de técnicas de agrupación semántica para analizar afinidades temáticas entre investigadores. De este modo, el proyecto aborda tareas de recopilación, limpieza, integración, modelado, visualización e interpretación de datos.

1.1 Motivación

En un entorno académico e investigador, gran parte de la información relevante sobre los miembros de un instituto se encuentra repartida entre directorios web, plataformas bibliográficas, bases de datos institucionales y otras fuentes externas. Aunque cada una de estas fuentes aporta información útil, la falta de uniformidad entre ellas dificulta su explotación conjunta y complica la obtención de una visión global del instituto.

En el caso del IUMPA, resultaba de especial interés disponer de una base de datos organizada y de una herramienta que permitiese analizar tanto las relaciones entre investigadores como sus publicaciones, revistas y proyectos asociados. A partir de esta necesidad, el trabajo se planteó como una oportunidad para aplicar conocimientos de ciencia de datos a un caso real, abordando un problema de recopilación, integración, modelado, visualización y análisis temático de la información.

1.2 Objetivos

El objetivo principal de este trabajo es diseñar una base de datos estructurada de la actividad investigadora del IUMPA y desarrollar herramientas que permitan analizarla y visualizarla de forma comprensible.

De forma más específica, los objetivos perseguidos son los siguientes:

- Identificar las entidades y relaciones relevantes para describir la actividad investigadora del instituto.

- Recopilar información procedente de distintas fuentes públicas y transformarla en bases de datos organizadas y coherentes.
- Resolver problemas de calidad de datos, duplicidad, formatos heterogéneos e información incompleta.
- Desarrollar una aplicación interactiva en R y Shiny que permita explorar visualmente la información mediante grafos.
- Analizar afinidades temáticas entre investigadores a partir de sus publicaciones y de las revistas en las que publican.
- Evaluar distintas estrategias de agrupación hasta obtener una representación temática suficientemente interpretable.

1.3 Alcance del trabajo

El alcance de este trabajo comprende el diseño y desarrollo de una base de datos orientada a representar la actividad investigadora del IUMPA a partir de información procedente de fuentes públicas y accesibles. En concreto, el proyecto se centra en la recopilación, depuración y estructuración de datos relacionados con investigadores, publicaciones, revistas, proyectos y relaciones de colaboración, así como en su posterior explotación mediante herramientas de visualización y análisis.

El trabajo incluye el desarrollo de una aplicación interactiva en R mediante Shiny, destinada a facilitar la exploración visual de la información mediante grafos. Estos grafos permiten representar distintas relaciones entre los elementos del sistema, como colaboraciones entre investigadores, publicaciones en revistas y participación en proyectos. Además, se incorpora una ampliación analítica basada en la extracción de palabras clave y en la aplicación de técnicas de agrupación semántica, con el objetivo de identificar afinidades temáticas entre investigadores.

El sistema desarrollado debe entenderse como una herramienta exploratoria y analítica orientada a facilitar la comprensión de la actividad investigadora del instituto. Por tanto, su finalidad no es establecer clasificaciones personales ni métricas comparativas de productividad entre investigadores, sino proporcionar una base estructurada que permita consultar y analizar la información recopilada desde una perspectiva relacional y temática. Asimismo, el alcance del proyecto queda condicionado por la disponibilidad, calidad y homogeneidad de la información accesible en las fuentes consultadas.

1.4 Estructura de la memoria

La memoria se organiza en varios capítulos. En primer lugar, se introduce el problema abordado, la motivación del trabajo, los objetivos perseguidos y el alcance general del proyecto. A continuación, se presenta el contexto del problema y el estado del arte relacionado con la representación de información investigadora, las fuentes de datos utilizadas, las técnicas de visualización y los métodos de agrupación empleados. Después, se describe el diseño conceptual del sistema, el alcance final del proyecto y las principales decisiones adoptadas durante su desarrollo.

Posteriormente, se detalla el proceso de construcción de la base de datos, incluyendo la recopilación, limpieza y homogeneización de la información. A continuación, se presenta el desarrollo de la aplicación interactiva en Shiny y la construcción de los diferentes grafos

definidos para representar la actividad investigadora del instituto. Más adelante, se expone la ampliación analítica del trabajo, centrada en la extracción de palabras clave y en la agrupación semántica de investigadores mediante distintas metodologías. Finalmente, se discuten los resultados obtenidos y se recogen las conclusiones principales del proyecto, sus limitaciones y las posibles líneas de trabajo futuro.

CAPÍTULO 2

Estado del arte y contexto del problema

Este capítulo presenta el marco conceptual y técnico del trabajo, así como el estado del arte relacionado con los principales elementos del proyecto. En él se contextualiza el problema de representar información investigadora procedente de fuentes diversas, se describen los retos asociados a la integración de datos heterogéneos y se introducen los enfoques utilizados para su visualización y análisis, como los grafos, las aplicaciones interactivas y las técnicas de agrupación semántica.

2.1 Información investigadora y análisis de la actividad científica

Este apartado contextualizará el análisis de la actividad investigadora a partir de información bibliográfica e institucional. Se explicará qué tipo de elementos permiten describir dicha actividad, como investigadores, publicaciones, revistas, proyectos y colaboraciones, y por qué resulta útil organizarlos de forma estructurada para facilitar su consulta, análisis y explotación posterior. El apartado no desarrollará todavía las fuentes concretas utilizadas en el proyecto, sino que servirá para situar el problema general que motiva la construcción de la base de datos.

2.2 Representación y visualización de relaciones científicas

Este apartado presentará la representación mediante grafos como una forma adecuada de modelar relaciones científicas. Se introducirán los conceptos generales de nodos y aristas aplicados a colaboraciones, publicaciones, revistas y proyectos, y se justificará el interés de las visualizaciones interactivas para explorar estructuras relacionales de forma más clara que mediante listados o tablas estáticas. También se mencionará, a nivel conceptual, el papel de herramientas interactivas como Shiny y librerías de visualización como ECharts, sin entrar todavía en la implementación concreta de la aplicación desarrollada.

2.3 Agrupación temática de perfiles investigadores

Este apartado introducirá el análisis de afinidades temáticas entre perfiles investigadores. Se explicará que, además de estudiar relaciones explícitas de colaboración, puede ser útil comparar investigadores a partir de los temas asociados a sus publicaciones o a las revistas en las que publican. También se presentará el papel de las técnicas de agrupa-

ción y de las representaciones semánticas, como los embeddings, para detectar similitudes conceptuales entre perfiles, sin desarrollar aún los experimentos concretos realizados en el proyecto.

CAPÍTULO 3

Diseño conceptual y planificación del proyecto

Este capítulo describe el planteamiento inicial y el diseño conceptual del proyecto. Para ello, se presentan las entidades, relaciones y propiedades consideradas inicialmente, así como los criterios seguidos para estructurar la información y transformar el problema en un modelo de datos coherente.

Además, se explica cómo evolucionó dicho modelo al contrastarlo con la disponibilidad real de información, qué decisiones de diseño se adoptaron y qué elementos fueron modificados o descartados durante las primeras fases del trabajo. Finalmente, se recogen las principales limitaciones y consideraciones metodológicas, éticas y de reproducibilidad asociadas al proyecto, junto con la planificación general seguida para su desarrollo.

3.1 Planteamiento inicial del modelo

Este apartado describirá el modelo conceptual planteado al inicio del proyecto para representar la actividad investigadora del IUMPA. Se presentarán las entidades consideradas relevantes, como investigadores, revistas, áreas, publicaciones y proyectos, así como las relaciones previstas entre ellas. También se explicará qué tipo de información se pretendía recoger para cada elemento y cómo este planteamiento inicial servía como punto de partida para organizar los datos de forma estructurada.

3.2 Evolución del diseño, limitaciones y decisiones adoptadas

Este apartado explicará cómo evolucionó el diseño inicial al contrastarlo con la disponibilidad, calidad y homogeneidad de la información accesible. Se describirán las principales decisiones adoptadas durante el desarrollo del proyecto, incluyendo los elementos que fueron modificados, simplificados o descartados por falta de datos fiables, por redundancia con otras variables o por no aportar suficiente valor al objetivo final del trabajo.

También se recogerán las principales limitaciones y consideraciones metodológicas, éticas y de reproducibilidad asociadas a estas decisiones. Se aclarará que el sistema se apoya en información pública y accesible, que su finalidad es exploratoria y analítica, no evaluativa, y que no pretende establecer clasificaciones personales ni métricas comparativas de productividad. Asimismo, se indicará qué partes del proceso pueden reproducirse mediante código y qué decisiones requirieron intervención manual o validación específica.

3.3 Planificación del trabajo

Este apartado describirá la organización general seguida durante el desarrollo del proyecto. Se presentarán las principales fases del trabajo, desde la definición inicial del modelo y la búsqueda de fuentes de información hasta la construcción de la base de datos, el desarrollo de la aplicación interactiva, la ampliación analítica mediante agrupación semántica y la interpretación de resultados. Esta planificación permitirá mostrar la evolución del TFG y conectar las decisiones de diseño con las etapas posteriores de implementación y análisis.

CAPÍTULO 4

Construcción de la base de datos

4.1 Fuentes de datos

Aquí se describirán las fuentes finalmente utilizadas para recopilar la información del proyecto. Entre ellas destacan la web del IUMPA, Google Scholar, Scopus, ORCID, Panorama UPV y otras fuentes auxiliares empleadas para completar o contrastar información.

Se justificará qué tipo de información se extrajo de cada una de ellas, así como las limitaciones encontradas en cada caso.

4.2 Obtención y depuración de los datos

En esta sección se explicará el proceso de recopilación de la información, incluyendo el uso de técnicas de web scraping, el tratamiento de ficheros intermedios y la construcción de bases de datos en formato tabular.

También se describirán con detalle las tareas de limpieza realizadas: corrección de errores tipográficos, tratamiento de codificaciones, homogeneización de nombres de investigadores y revistas, resolución de duplicidades y tratamiento manual de casos ambiguos o erróneos.

4.3 Estructura final de las bases de datos

Finalmente, se describirá la estructura definitiva de las bases de datos construidas durante el proyecto, detallando qué entidades quedaron finalmente incluidas, qué relaciones se conservaron y qué elementos fueron descartados por inviabilidad o por escaso interés analítico.

CAPÍTULO 5

Desarrollo de la aplicación interactiva

5.1 Diseño general de la herramienta

Este capítulo se centrará en la construcción de la aplicación web en R mediante Shiny. Se explicará la arquitectura general de la herramienta, su organización interna y la lógica seguida para convertir la información almacenada en grafos interactivos.

5.2 Grafos de investigadores, publicaciones y proyectos

Aquí se detallarán los diferentes grafos desarrollados para representar las relaciones entre investigadores, revistas, publicaciones y proyectos. Se explicará qué información muestra cada uno de ellos, qué tipo de interacción permite y cómo se construyeron a partir de las bases de datos disponibles.

5.3 Visualización, filtros e interpretación

En esta sección se describirán los elementos de interacción incorporados a la aplicación, como selectores, paneles informativos o filtros por áreas. También se analizarán las decisiones de diseño adoptadas para mejorar la comprensión visual de los datos y facilitar la interpretación de las relaciones representadas.

CAPÍTULO 6

Agrupación semántica de investigadores

6.1 Construcción de las palabras clave

Este capítulo recogerá la ampliación analítica final del proyecto. En primer lugar, se explicará el proceso seguido para obtener palabras clave representativas de las revistas en las que habían publicado los investigadores del IUMPA, así como la construcción de las matrices necesarias para asociar dichas palabras a cada investigador.

6.2 Primeros enfoques de agrupación

A continuación, se presentarán las primeras pruebas realizadas con modelos de clustering basados en coincidencias literales de palabras clave, matrices binarias y diferentes distancias. Se analizarán sus limitaciones y se justificará por qué estos enfoques no resultaron suficientes para obtener agrupaciones sólidas e interpretables.

6.3 Embeddings y clustering semántico

Posteriormente, se describirá el cambio de enfoque hacia una representación semántica mediante embeddings, así como la aplicación de métodos de clustering jerárquico y reducción de dimensionalidad. Se explicará el proceso experimental seguido, los criterios de evaluación empleados y la comparación entre distintas alternativas.

6.4 Interpretación de resultados

Por último, se analizarán los resultados obtenidos, prestando atención tanto a las métricas cuantitativas como a la coherencia temática de los grupos identificados. Se discutirán las fortalezas y limitaciones del enfoque finalmente adoptado.

CAPÍTULO 7

Resultados y discusión

En este capítulo se integrarán y discutirán los resultados globales del proyecto. Por un lado, se valorará la utilidad de la base de datos construida y de la aplicación desarrollada para representar la estructura investigadora del IUMPA. Por otro, se contextualizarán los resultados obtenidos en la fase de agrupación semántica, analizando hasta qué punto complementan la información relacional mostrada por los grafos.

También se comentarán las principales dificultades encontradas a lo largo del trabajo, el impacto de las limitaciones de los datos sobre los resultados finales y el grado en que los objetivos iniciales han sido alcanzados.

CAPÍTULO 8

Conclusiones y trabajo futuro

A lo largo de este Trabajo Fin de Grado se ha diseñado y desarrollado una base de datos estructurada de la actividad investigadora del Instituto Universitario de Matemática Pura y Aplicada, integrando información procedente de múltiples fuentes y transformándola en un sistema coherente y explotable. Este proceso ha permitido no solo organizar la información de investigadores, publicaciones, revistas y proyectos, sino también convertirla en una herramienta visual e interactiva útil para explorar la estructura investigadora del instituto.

Además, el trabajo ha ido más allá de la mera representación relacional de la información, incorporando una línea de análisis temático orientada a identificar afinidades entre investigadores a partir de sus publicaciones. Aunque los primeros enfoques de agrupación presentaron limitaciones importantes, la adopción de una representación semántica mediante embeddings permitió obtener resultados más interpretables y adecuados al problema planteado.

En conjunto, el proyecto ha permitido abordar un problema real de ciencia de datos en todas sus fases: definición del modelo, obtención de información, limpieza y validación de datos, diseño de visualizaciones y análisis avanzado. Como líneas de trabajo futuro, resulta natural plantear la ampliación de las fuentes institucionales empleadas, la actualización periódica de la base de datos, la mejora de la parte analítica y la incorporación de nuevas funcionalidades a la plataforma interactiva.

Bibliografía

- [1] Chang, W., Cheng, J., Allaire, J., Sievert, C., Schloerke, B., Xie, Y., Allen, J., McPherson, J., Dipert, A. y Borges, B. *Shiny: Web Application Framework for R*. R package.
- [2] Apache Software Foundation. *Apache ECharts*. Disponible en: <https://echarts.apache.org/>
- [3] Elsevier. *Scopus*. Disponible en: <https://www.scopus.com/>
- [4] Google. *Google Scholar*. Disponible en: <https://scholar.google.com/>
- [5] ORCID. *ORCID*. Disponible en: <https://orcid.org/>
- [6] McInnes, L., Healy, J. y Melville, J. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. *arXiv preprint arXiv:1802.03426*, 2018.
- [7] Hastie, T., Tibshirani, R. y Friedman, J. *The Elements of Statistical Learning*. Springer, 2009.
- [8] Manning, C. D., Raghavan, P. y Schütze, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.

APÉNDICE A

Relación del trabajo con los Objetivos de Desarrollo Sostenible

Este anexo recogerá la relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS), de acuerdo con las directrices establecidas por la ETSINF para los Trabajos Fin de Grado. En la versión final de la memoria, aquí deberá incorporarse la justificación de los ODS con los que el proyecto guarda una relación más directa, explicando de qué manera contribuye a ellos y cuál es el alcance real de dicha contribución.

APÉNDICE B

Material complementario

En este anexo podrán incluirse tablas extensas, esquemas auxiliares, detalles técnicos adicionales, capturas ampliadas de la aplicación o cualquier otro material complementario que ayude a entender mejor el trabajo sin sobrecargar el cuerpo principal de la memoria.