

Resum

Aquest treball presenta el disseny i desenvolupament d'una base de dades estructurada per a descriure l'activitat investigadora de l'Institut Universitari de Matemàtica Pura i Aplicada (IUMPA). A partir d'informació procedent de diferents fonts públiques, es va construir un sistema organitzat que permet representar investigadors, publicacions, revistes, projectes i relacions de col·laboració entre ells. El procés va requerir tasques de recopilació, depuració, homogeneïtzació i validació de dades, així com el disseny d'estructures intermèdies que permeten transformar informació dispersa en un conjunt de dades coherent i explotable.

Sobre aquesta base, es va desenvolupar una aplicació interactiva en R mitjançant la llibreria Shiny, en la qual s'integren diferents grafs que permeten explorar visualment les relacions entre investigadors, les seues publicacions i els projectes en els quals participen. L'objectiu d'esta plataforma és facilitar la consulta i l'anàlisi de l'estructura investigadora de l'institut d'una manera accessible i intuïtiva.

Com a ampliació analítica, es va abordar l'estudi d'afinitats temàtiques entre investigadors a partir de les revistes en les quals han publicat. Per a això es van extraure paraules clau representatives, es van construir matrius de dades específiques i es van avaluar diferents estratègies d'agrupació. Després de comprovar les limitacions dels enfocaments basats en coincidències literals de paraules, es va adoptar una representació semàntica mitjançant "word embeddings", sobre la qual es van aplicar tècniques de clustering jeràrquic i reducció de dimensionalitat, amb l'objectiu d'identificar perfils investigadors similars que puguin afavorir la col·laboració i el treball en equip entre investigadors amb nuclis temàtics afins. Els resultats obtinguts permeten complementar la visió relacional dels grafs amb una aproximació temàtica a l'activitat investigadora de l'IUMPA.

Tot plegat, el treball ofereix un marc general per comprendre millor l'estructura investigadora de l'institut, a més d'establir una base per a futures ampliacions d'anàlisi i visualització.

Paraules clau: IUMPA, bases de dades, visualització, grafs, aprenentatge automàtic, agrupació semàntica

Resumen

Este trabajo presenta el diseño y desarrollo de una base de datos estructurada para describir la actividad investigadora del Instituto Universitario de Matemática Pura y Aplicada (IUMPA). A partir de información procedente de distintas fuentes públicas, se construyó un sistema organizado que permite representar investigadores, publicaciones, revistas, proyectos y relaciones de colaboración entre ellos. El proceso requirió tareas de recopilación, depuración, homogeneización y validación de datos, así como el diseño de estructuras intermedias que permitieran transformar información dispersa en un conjunto de datos coherente y explotable.

Sobre esta base, se desarrolló una aplicación interactiva en R mediante la librería Shiny, en la que se integran diferentes grafos que permiten explorar visualmente las relaciones entre investigadores, sus publicaciones y los proyectos en los que participan. El objetivo de esta plataforma es facilitar la consulta y el análisis de la estructura investigadora del instituto de una forma accesible e intuitiva.

Como ampliación analítica, se abordó el estudio de afinidades temáticas entre investigadores a partir de las revistas en las que han publicado. Para ello se extrajeron palabras

clave representativas, se construyeron matrices de datos específicas y se evaluaron distintas estrategias de agrupación. Tras comprobar las limitaciones de los enfoques basados en coincidencias literales de palabras, se adoptó una representación semántica mediante "word embeddings", sobre la que se aplicaron técnicas de clustering jerárquico y reducción de dimensionalidad, con el objetivo de identificar perfiles investigadores similares que puedan facilitar la colaboración y el trabajo en equipo entre investigadores con núcleos temáticos afines. Los resultados obtenidos permiten complementar la visión relacional de los grafos con una aproximación temática a la actividad investigadora del IUMPA.

En conjunto, el trabajo ofrece un marco general para comprender mejor la estructura investigadora del instituto, además de establecer una base para futuras ampliaciones de análisis y visualización.

Palabras clave: IUMPA, base de datos, visualización, grafos, aprendizaje automático, agrupación semántica

Abstract

This thesis presents the design and development of a structured database to describe the research activity of the Instituto Universitario de Matemática Pura y Aplicada (IUMPA). Using information collected from several public sources, an organized system was built to represent researchers, publications, journals, projects, and collaboration links among them. The process required data collection, cleaning, homogenization, and validation tasks, as well as the design of intermediate data structures to transform scattered information into a coherent and usable dataset.

Based on this dataset, an interactive application was developed in R using the Shiny library. The application integrates several graphs that allow visual exploration of the relationships between researchers, their publications, and the projects in which they participate. The objective of this platform is to make it possible to consult and analyze the institute's research structure in an accessible and intuitive way.

As an analytical extension, thematic affinities among researchers were studied using the journals in which they had published. To achieve this, representative keywords were extracted, specific data matrices were built, and different clustering strategies were evaluated. After observing the limitations of approaches based on literal keyword matching, a semantic representation based on word embeddings was adopted, and hierarchical clustering and dimensionality reduction techniques were applied, with the aim of identifying similar research profiles that may support collaboration and teamwork among researchers with related thematic areas. The obtained results complement the relational view provided by the graphs with a thematic perspective on IUMPA's research activity.

Overall, this work provides a general framework for better understanding the institute's research structure and establishes a basis for future extensions in both analysis and visualization.

Key words: IUMPA, database, visualization, graphs, machine learning, semantic clustering

Índice general

Índice general	v
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Alcance del trabajo	2
1.4 Estructura de la memoria	2
2 Contexto del problema y estado del arte	5
2.1 Información investigadora y análisis de la actividad científica	5
2.2 Representación y visualización de relaciones científicas	6
2.3 Agrupación temática de perfiles investigadores	7
3 Diseño conceptual y planificación del proyecto	9
3.1 Planteamiento inicial del modelo	9
3.2 Evolución del diseño, limitaciones y decisiones adoptadas	11
3.3 Planificación del trabajo	13
4 Construcción de la base de datos	15
4.1 Fuentes de datos	15
4.2 Extracción y organización inicial de la información	15
4.3 Depuración, homogeneización y validación de los datos	15
4.4 Estructura final de las bases de datos	16
4.5 Valoración de la base de datos construida	16
5 Desarrollo de la aplicación interactiva	17
5.1 Diseño general de la herramienta	17
5.2 Construcción de los grafos interactivos	17
5.3 Elementos de interacción y visualización	17
5.4 Valoración de la aplicación desarrollada	18
6 Agrupación semántica de investigadores	19
6.1 Construcción de palabras clave	19
6.2 Representación temática de los investigadores	19
6.3 Modelos de clustering	19
6.4 Evaluación y discusión de los resultados	20
7 Conclusiones y trabajo futuro	21
7.1 Conclusiones generales	21
7.2 Cumplimiento de los objetivos	21
7.3 Líneas de trabajo futuro	21
Bibliografía	23
Apéndices	
A Relación del trabajo con los Objetivos de Desarrollo Sostenible	25
B Material complementario	27

CAPÍTULO 1

Introducción

El presente Trabajo Fin de Grado se enmarca en el ámbito del análisis de datos, la estructuración de información investigadora y su posterior explotación mediante técnicas de visualización y agrupación semántica. El proyecto se centra en el Instituto Universitario de Matemática Pura y Aplicada (IUMPA), con el objetivo de organizar información relativa a sus investigadores, publicaciones, revistas, proyectos y relaciones de colaboración.

A partir de esta información, se plantea una solución que combina tres componentes principales: la construcción de una base de datos estructurada, el desarrollo de una aplicación interactiva para la visualización de relaciones mediante grafos y la aplicación de técnicas de agrupación semántica para analizar afinidades temáticas entre investigadores. De este modo, el proyecto aborda tareas de recopilación, limpieza, integración, modelado, visualización e interpretación de datos.

1.1 Motivación

En un entorno académico e investigador, gran parte de la información relevante sobre los miembros de un instituto se encuentra repartida entre directorios web, plataformas bibliográficas, bases de datos institucionales y otras fuentes externas. Aunque cada una de estas fuentes aporta información útil, la falta de uniformidad entre ellas dificulta su explotación conjunta y complica la obtención de una visión global del instituto.

En el caso del IUMPA, resultaba de especial interés disponer de una base de datos organizada y de una herramienta que permitiese analizar tanto las relaciones entre investigadores como sus publicaciones, revistas y proyectos asociados. A partir de esta necesidad, el trabajo se planteó como una oportunidad para aplicar conocimientos de ciencia de datos a un caso real, abordando un problema de recopilación, integración, modelado, visualización y análisis temático de la información.

1.2 Objetivos

El objetivo principal de este trabajo es diseñar una base de datos estructurada de la actividad investigadora del IUMPA y desarrollar herramientas que permitan analizarla y visualizarla de forma comprensible.

De forma más específica, los objetivos perseguidos son los siguientes:

- Identificar las entidades y relaciones relevantes para describir la actividad investigadora del instituto.

- Recopilar información procedente de distintas fuentes públicas y transformarla en bases de datos organizadas y coherentes.
- Resolver problemas de calidad de datos, duplicidad, formatos heterogéneos e información incompleta.
- Desarrollar una aplicación interactiva en R y Shiny que permita explorar visualmente la información mediante grafos.
- Analizar afinidades temáticas entre investigadores a partir de sus publicaciones y de las revistas en las que publican.
- Evaluar distintas estrategias de agrupación hasta obtener una representación temática suficientemente interpretable.

1.3 Alcance del trabajo

El alcance de este trabajo comprende el diseño y desarrollo de una base de datos orientada a representar la actividad investigadora del IUMPA a partir de información procedente de fuentes públicas y accesibles. En concreto, el proyecto se centra en recopilar, tratar y estructurar datos relacionados con los investigadores del instituto, así como de su actividad investigadora (publicaciones, revistas y proyectos) y de sus relaciones de colaboración. Esta base de datos final se explota mediante herramientas de visualización y análisis.

El trabajo incluye el desarrollo de una aplicación interactiva en R mediante Shiny, destinada a facilitar la exploración visual de la información mediante grafos. Estos grafos permiten representar distintas relaciones entre los elementos del sistema, como colaboraciones entre investigadores, publicaciones en revistas y participación en proyectos. Además, se incorpora una ampliación analítica basada en la extracción de palabras clave y en la aplicación de técnicas de agrupación semántica, con el objetivo de identificar afinidades temáticas entre investigadores.

El sistema desarrollado debe entenderse como una herramienta exploratoria y analítica orientada a facilitar la comprensión de la actividad investigadora del instituto. Por tanto, su finalidad no es establecer clasificaciones personales ni métricas comparativas de productividad entre investigadores, sino proporcionar una base estructurada que permita consultar y analizar la información recopilada desde una perspectiva relacional y temática. Asimismo, el alcance del proyecto queda condicionado por la disponibilidad, calidad y homogeneidad de la información accesible en las fuentes consultadas.

1.4 Estructura de la memoria

La memoria se organiza en varios capítulos. En primer lugar, se introduce el problema abordado, la motivación del trabajo, los objetivos perseguidos y el alcance general del proyecto. A continuación, se presenta el contexto del problema y el estado del arte relacionado con la representación de información investigadora, la integración de información procedente de fuentes heterogéneas, las técnicas de visualización y los métodos de agrupación empleados.

Después, se describe el diseño conceptual del sistema, la evolución del modelo inicial y las principales decisiones adoptadas durante el desarrollo del proyecto. Posteriormente, se detalla el proceso de construcción de la base de datos, incluyendo la recopilación, limpieza y homogeneización de la información. A continuación, se presenta el desarrollo de

la aplicación interactiva en Shiny y la construcción de los diferentes grafos definidos para representar la actividad investigadora del instituto.

Más adelante, se expone la ampliación analítica del trabajo, centrada en la extracción de palabras clave y en la agrupación semántica de investigadores mediante distintas metodologías. Finalmente, se sintetizan los resultados obtenidos y se recogen las conclusiones principales del proyecto, sus limitaciones y las posibles líneas de trabajo futuro.

CAPÍTULO 2

Contexto del problema y estado del arte

El análisis de la actividad investigadora requiere organizar información procedente de fuentes diversas y, con frecuencia, heterogéneas. Esta información suele encontrarse dispersa en plataformas bibliográficas, directorios institucionales y otras fuentes externas, lo que dificulta su consulta conjunta y limita la obtención de una visión global de la estructura científica de una institución. Por ello, resulta necesario definir modelos que permitan integrarla, relacionarla y explotarla de forma coherente.

Una vez estructurados los datos, su utilidad depende en gran medida de la forma en que puedan ser consultados e interpretados. Las tablas permiten almacenar la información de manera ordenada, pero no siempre facilitan la comprensión de las relaciones existentes entre los distintos elementos del sistema. En este sentido, los grafos constituyen una herramienta especialmente adecuada para representar vínculos, como la colaboración o la publicación,, mientras que las aplicaciones interactivas permiten explorar dichas relaciones de forma más flexible y comprensible.

Además de representar relaciones explícitas, como colaboraciones o participaciones comunes, también puede resultar útil analizar similitudes menos directas entre perfiles investigadores. Dos investigadores pueden estar próximos no solo porque hayan trabajado juntos, sino también porque desarrollen su actividad en ámbitos temáticos relacionados. Por este motivo, las técnicas de agrupación y las representaciones semánticas ofrecen una perspectiva complementaria, orientada a identificar afinidades temáticas a partir de la información disponible sobre la producción científica.

2.1 Información investigadora y análisis de la actividad científica

El análisis de la actividad científica de una institución requiere transformar información dispersa en una representación organizada y comprensible. La actividad investigadora no se refleja únicamente en los resultados finales, sino también en el contexto en el que estos se generan y en las relaciones que se establecen alrededor de ellos.

Desde esta perspectiva, la información bibliográfica e institucional constituye una base fundamental para estudiar la estructura científica de un centro. Más allá del valor particular de cada registro, su interés aumenta cuando los datos pueden relacionarse entre sí para describir distintas dimensiones de la actividad investigadora, como la producción científica, la colaboración entre miembros de la comunidad académica o la orientación temática de sus trabajos.

Este análisis se relaciona con enfoques propios de la bibliometría y del estudio de la actividad científica, que utilizan datos académicos para caracterizar la estructura investigadora de instituciones y comunidades. Esta visión conjunta permite identificar conexiones, patrones de colaboración y posibles afinidades temáticas que no serían evidentes a partir de elementos aislados.

Sin embargo, este tipo de información suele presentar dificultades importantes desde el punto de vista del tratamiento de datos. Es habitual que proceda de fuentes distintas, con formatos heterogéneos, criterios de identificación no siempre uniformes y distintos niveles de completitud. Por ello, antes de poder realizar cualquier análisis, resulta necesario recopilar, depurar y homogeneizar los datos, de forma que puedan analizarse de manera coherente.

La organización de esta información permite pasar de una colección de registros independientes a un sistema de datos explotable. Esta transformación facilita la consulta, mejora la trazabilidad de las relaciones entre elementos y proporciona una base adecuada para aplicar técnicas posteriores de visualización y análisis. En este sentido, la construcción de una base de datos no debe entenderse únicamente como una fase previa del proyecto, sino como un elemento central para poder representar y analizar de forma coherente la actividad investigadora.

2.2 Representación y visualización de relaciones científicas

Una vez organizada la información investigadora, una parte importante del análisis consiste en representar los vínculos que estructuran el sistema. En este tipo de contexto, no solo interesa consultar registros individuales, sino también comprender cómo se relacionan entre sí. Las colaboraciones entre investigadores, la participación en proyectos o la relación entre publicaciones y revistas son ejemplos de vínculos que pueden aportar información relevante sobre la estructura científica de una institución.

Los grafos constituyen una forma adecuada de modelar este tipo de relaciones, ya que permiten representar sistemas formados por entidades conectadas entre sí [1]. En ellos, los nodos representan las entidades del sistema y las aristas indican los vínculos existentes entre ellas. Esta representación permite pasar de una visión tabular, centrada en registros independientes, a una visión relacional, en la que las conexiones entre elementos ayudan a interpretar la estructura global de los datos. De este modo, los grafos facilitan la identificación de patrones de colaboración, elementos especialmente conectados o agrupaciones de entidades relacionadas.

Cuando el número de elementos y relaciones aumenta, la representación visual debe complementarse con mecanismos que faciliten la exploración de la información. La interactividad permite seleccionar elementos concretos, aplicar filtros, consultar información asociada y adaptar la visualización a distintas preguntas de análisis. Así, el usuario puede explorar la red de forma progresiva, pasando de una visión general del sistema a detalles específicos sobre determinados nodos o relaciones.

Herramientas como Shiny permiten construir aplicaciones web orientadas a la exploración de datos, mientras que librerías de visualización como ECharts facilitan la creación de grafos dinámicos e interactivos. Su uso permite transformar una representación estática de la información en un entorno de consulta más accesible.

2.3 Agrupación temática de perfiles investigadores

Las relaciones explícitas, como las colaboraciones entre autores, permiten describir una parte importante de la actividad investigadora, pero no siempre reflejan todas las proximidades existentes entre perfiles. También pueden existir afinidades temáticas entre investigadores que trabajan en ámbitos relacionados, aunque no hayan colaborado directamente, por lo que resulta útil complementar el análisis relacional con técnicas de agrupación temática.

Esta perspectiva permite comparar perfiles investigadores a partir de los temas asociados a su producción científica. Para ello, pueden emplearse elementos textuales o descriptivos relacionados con las publicaciones, las revistas o los términos que caracterizan dichas fuentes, con el fin de construir una representación que recoja los intereses principales de cada investigador. Este planteamiento se relaciona con enfoques habituales de recuperación de información y representación textual, donde los documentos o términos se transforman en estructuras comparables para poder analizar su similitud [2]. A partir de estas representaciones, es posible estudiar qué perfiles presentan mayor proximidad temática y qué grupos comparten características similares.

Las técnicas de agrupación permiten organizar estos perfiles en conjuntos de elementos similares sin necesidad de definir previamente una clasificación cerrada, por lo que se enmarcan dentro de los métodos de aprendizaje no supervisado [3]. En este contexto, el clustering resulta útil para explorar si existen patrones latentes en los datos y para identificar posibles grupos de investigadores con afinidades comunes. No obstante, la calidad de estas agrupaciones depende en gran medida de cómo se represente la información de partida, especialmente cuando se trabaja con datos textuales o temáticos.

Por este motivo, las representaciones semánticas, como los *word embeddings*, ofrecen una alternativa más rica que la comparación literal de palabras. Estos modelos permiten representar términos en espacios vectoriales continuos, de forma que la proximidad entre vectores puede reflejar relaciones de similitud sintáctica o semántica [4]. Mientras que los enfoques basados únicamente en coincidencias exactas pueden no detectar relaciones entre términos distintos pero conceptualmente próximos, los embeddings permiten incorporar información semántica a la comparación entre perfiles. De esta forma, es posible comparar perfiles investigadores no solo por las palabras concretas asociadas a ellos, sino también por la cercanía conceptual entre sus temas de trabajo.

La agrupación temática proporciona así una visión complementaria a la obtenida mediante grafos de colaboración o participación. Mientras que la representación relacional muestra conexiones explícitas, el análisis semántico permite explorar afinidades menos evidentes y enriquecer la comprensión de la estructura científica de una institución.

CAPÍTULO 3

Diseño conceptual y planificación del proyecto

Antes de iniciar la construcción de la base de datos, fue necesario definir un modelo conceptual que permitiera representar de forma ordenada la actividad investigadora del IUMPA. Este planteamiento sirvió para identificar qué elementos debían formar parte del sistema, qué relaciones podían establecerse entre ellos y qué información resultaba relevante para describirlos.

No obstante, el diseño de esta base de datos no dependía únicamente del modelo que se deseaba construir, sino también de la disponibilidad, calidad y homogeneidad de los datos accesibles. Por ello, el modelo inicial tuvo que contrastarse con las fuentes de información disponibles y ajustarse progresivamente a las limitaciones encontradas durante el desarrollo del proyecto.

De esta forma, el diseño conceptual no se entiende como una fase cerrada desde el inicio, sino como un proceso progresivo en el que las decisiones técnicas se fueron ajustando a las características reales de la información disponible.

3.1 Planteamiento inicial del modelo

El primer paso del proyecto consistió en definir un modelo conceptual que permitiera representar la actividad investigadora del IUMPA de forma estructurada. Antes de iniciar la recopilación de datos, se identificaron las principales entidades que podían intervenir en el sistema y las relaciones que permitirían conectar la información entre ellas. Este planteamiento inicial se concibió como una primera aproximación al problema, destinada a orientar la búsqueda de información y definir las necesidades de datos.

En esta primera fase se consideraron como entidades principales los investigadores internos del instituto, las revistas, las áreas de trabajo y los proyectos de investigación. Para cada una de ellas se definieron una serie de propiedades básicas:

- **Investigadores internos:** representaban a los miembros del IUMPA sobre los que se quería estructurar la información principal del sistema. Inicialmente se planteó almacenar atributos como el nombre, un identificador, el correo electrónico, el tipo de empleado y los acrónimos y firmas utilizadas para identificar sus publicaciones.
- **Revistas:** recogían los medios en los que aparecían los artículos publicados por los investigadores. Para esta entidad se contemplaron propiedades como el nombre de la revista, un identificador y el grupo editorial.

- **Áreas de trabajo:** permitían representar las líneas de investigación asociadas a los investigadores del instituto. En el planteamiento inicial se concibieron como una forma de contextualizar temáticamente la actividad investigadora.
- **Proyectos de investigación:** se planteaban como elementos vinculados a la actividad investigadora financiada. Para ellos se consideraron propiedades como el título, un identificador, el importe, las fechas de inicio y fin, el número de investigadores participantes y el tipo de proyecto.

Aunque el foco principal del modelo se situó desde el inicio en los investigadores internos del IUMPA, también se contempló la posibilidad de recopilar información sobre investigadores externos que hubieran publicado con ellos. Esta información podía resultar útil para estudiar si existían colaboradores externos recurrentes, así como para ofrecer una visión más amplia de las relaciones científicas del instituto. No obstante, estos investigadores externos se entendían como elementos auxiliares del análisis, no como el núcleo principal del sistema.

Además de estas entidades, el modelo inicial incorporaba varias relaciones orientadas a representar la actividad científica del instituto:

- ***ha_publicado_en*:** relación destinada a vincular a cada investigador con las revistas en las que había publicado. Esta relación incorporaba información asociada a las publicaciones, como el título del artículo y el año de publicación.
- ***ha_publicado_con*:** relación planteada para conectar investigadores que hubieran publicado artículos conjuntamente. Su objetivo era representar colaboraciones científicas derivadas de publicaciones compartidas.
- ***ha_participado_en*:** relación pensada para vincular investigadores internos y proyectos de investigación. A través de ella se pretendía representar la participación de los investigadores en los proyectos recopilados, incorporando además una variable que indicara si actuaban como investigadores principales en cada proyecto.
- ***ha_participado_con*:** relación orientada a conectar investigadores que hubieran coincidido en un mismo proyecto. Su objetivo era representar colaboraciones derivadas de la participación común en proyectos de investigación.
- ***es_parte_de*:** relación definida para asociar investigadores con sus áreas de trabajo, permitiendo representar los ámbitos temáticos o líneas de investigación en los que participaban.

Este modelo partía de una visión relacional del problema, ya que no se trataba únicamente de almacenar registros independientes, sino de representar cómo se conectaban entre sí los distintos elementos de la actividad investigadora. Por este motivo, en la fase inicial se valoró la posibilidad de utilizar una base de datos orientada a grafos, como Neo4j, ya que este tipo de tecnología resultaba coherente con un modelo basado en entidades y relaciones.

No obstante, en esta etapa del proyecto la prioridad no era cerrar todavía la solución técnica definitiva, sino definir un esquema conceptual suficientemente claro para guiar la recopilación y organización de los datos. La elección concreta de la implementación quedaba condicionada por factores prácticos, como la disponibilidad real de la información, el formato de los datos obtenidos y las necesidades posteriores de visualización en la aplicación interactiva. En consecuencia, la consideración de Neo4j actuó más como una referencia conceptual para pensar el modelo en términos de nodos y relaciones que como una decisión cerrada de implementación desde el inicio.

3.2 Evolución del diseño, limitaciones y decisiones adoptadas

La definición inicial del modelo sirvió como punto de partida, pero su desarrollo tuvo que adaptarse a la disponibilidad real de información. Aunque el planteamiento permitía representar de forma amplia la actividad investigadora del IUMPA, no todos los elementos previstos podían obtenerse con el mismo grado de completitud. Por ello, durante las primeras fases del proyecto fue necesario revisar algunas entidades, propiedades y relaciones, manteniendo aquellas que aportaban valor al objetivo final del trabajo y descartando las que introducían complejidad sin garantizar la calidad de los datos.

Una de las primeras decisiones relevantes fue centrar el modelo en los investigadores internos del IUMPA. Inicialmente se contempló la posibilidad de recopilar también información sobre investigadores externos que hubieran publicado con ellos, con el fin de detectar posibles colaboradores recurrentes y ampliar la visión de las relaciones científicas del instituto. Sin embargo, esta opción se descartó como parte central del modelo, ya que la identificación y validación de investigadores externos introducía una dificultad adicional considerable y desviaba el foco principal del proyecto. Por tanto, los investigadores externos no se incorporaron como entidad principal, manteniéndose el análisis centrado en la actividad de los miembros del instituto.

También se revisaron algunas propiedades inicialmente planteadas para los investigadores internos. En concreto, se descartó el atributo de tipo de empleado, al no disponer de una fuente que permitiera diferenciarlo de forma fiable para todos los investigadores. Asimismo, se decidió no incorporar el grupo de investigación como propiedad independiente, ya que su información resultaba poco diferenciada respecto a las áreas de trabajo. Por este motivo, las áreas se mantuvieron como la referencia principal para contextualizar temáticamente a los investigadores.

En el caso de las revistas, se mantuvo la entidad como medio de publicación, pero la información específica de cada artículo se incorporó a la relación *ha_publicado_en*. De este modo, el modelo distinguía entre los datos propios de la revista y los datos asociados a cada publicación concreta.

En la parte relativa a proyectos de investigación, el principal ajuste consistió en descartar el importe económico como atributo central del modelo. Aunque inicialmente se había contemplado recoger esta información, finalmente no se mantuvo en el análisis al no resultar necesaria para los objetivos principales de visualización y exploración.

Otro cambio importante tuvo que ver con la implementación práctica del modelo. Aunque inicialmente se valoró la posibilidad de utilizar una base de datos orientada a grafos, el desarrollo del proyecto se fue adaptando a las características reales de los datos obtenidos. La información procedía de fuentes diversas y requería numerosas tareas de depuración, homogeneización y validación, por lo que resultó conveniente trabajar con estructuras tabulares intermedias que permitieran revisar los datos de forma controlada. A partir de estas estructuras era factible generar los grafos para la visualización interactiva, manteniendo así la lógica relacional del modelo.

Estas decisiones estuvieron condicionadas por varias limitaciones propias del trabajo con información pública y heterogénea. Algunas fuentes no ofrecían información completa para todos los investigadores, otras presentaban diferencias de formato o criterios de identificación, y en determinados casos fue necesario validar manualmente nombres, firmas, revistas o relaciones ambiguas. Por ello, la ausencia de información en la base de datos no debe interpretarse como falta de actividad investigadora, sino como una consecuencia de las limitaciones de accesibilidad de las fuentes consultadas.

Desde el punto de vista metodológico, el sistema desarrollado debe entenderse como una herramienta exploratoria y analítica. Su finalidad no es evaluar individualmente a los investigadores ni establecer métricas comparativas de productividad, sino organizar información dispersa y facilitar su consulta desde una perspectiva relacional y temática. Esta consideración resulta especialmente importante al trabajar con datos asociados a personas, aunque procedan de fuentes públicas, ya que el objetivo del proyecto es representar la estructura investigadora del instituto y no clasificar el rendimiento individual de sus miembros.

Por último, la evolución del diseño también tuvo implicaciones en la reproducibilidad del proceso. Una parte del trabajo pudo automatizarse mediante código, especialmente aquellas tareas relacionadas con la extracción inicial de información, la lectura de ficheros, la transformación de datos y la generación de estructuras para los grafos. Sin embargo, otras fases requirieron intervención manual o validación específica, como ocurrió en la revisión de nombres, firmas, revistas, áreas de trabajo, duplicidades y registros ambiguos.

Por tanto, la reproducibilidad del proyecto debe entenderse de forma parcial. Los códigos desarrollados permiten reproducir las transformaciones y estructuras generadas a partir de los datos de entrada, pero parte de la calidad final de la base de datos depende de decisiones supervisadas y de revisiones manuales realizadas durante el proceso. Esta distinción resulta relevante para interpretar el alcance metodológico del trabajo, ya que la construcción de la base de datos combinó procedimientos automatizados con tareas de validación manual. Estas fases se desarrollarán en detalle al describir el proceso de construcción de la base de datos.

Tras la revisión del planteamiento inicial, el modelo quedó centrado en un conjunto de entidades y relaciones orientadas a representar la actividad investigadora del IUMPA desde una perspectiva relacional. El estado final del modelo conceptual puede resumirse de la siguiente forma:

- **Investigadores internos:** se mantuvieron como entidad principal del modelo. Sobre ellos se estructura la información recopilada, incluyendo datos identificativos como el nombre, el correo electrónico y las firmas o acrónimos utilizados para identificar sus publicaciones.
- **Revistas:** se mantuvieron como entidad del modelo, entendidas como los medios en los que se publican los artículos asociados a los investigadores. Recogen información propia de la revista, como su nombre y grupo editorial.
- **Áreas de trabajo:** se mantuvieron como entidad de contextualización temática. Permiten asociar a los investigadores internos con sus líneas de trabajo.
- **Proyectos de investigación:** se mantuvieron como entidad del modelo. Permiten representar la participación de los investigadores internos en proyectos de investigación.
- **Relaciones por publicaciones:** se representaron mediante las relaciones *ha_publicado_en* y *ha_publicado_con*. La primera vincula investigadores con revistas e incorpora información asociada a los artículos, como el título y el año de publicación; la segunda permite identificar qué investigadores han publicado artículos conjuntamente.
- **Relaciones por proyectos:** se representaron mediante las relaciones *ha_participado_en* y *ha_participado_con*. La primera vincula investigadores internos con proyectos e incorpora la información relativa a si el investigador actúa como principal en cada proyecto; la segunda permite identificar qué investigadores coinciden en proyectos comunes.

- **Relación con áreas:** se mantuvo mediante la relación *es_parte_de*, destinada a asociar investigadores internos con sus áreas de trabajo.

3.3 Planificación del trabajo

El desarrollo del proyecto se organizó en varias fases sucesivas, aunque no completamente independientes entre sí. Debido a la naturaleza del trabajo con datos reales, algunas etapas requirieron volver sobre decisiones anteriores, revisar información ya recopilada o modificar parte del modelo inicial. Por ello, esta planificación debe entenderse como un proceso iterativo, en el que el diseño conceptual, la disponibilidad de los datos y las necesidades de visualización fueron condicionando la evolución del proyecto.

La primera fase estuvo centrada en la definición del problema y del modelo conceptual inicial. En esta etapa se identificaron las entidades y relaciones que podían representar la actividad investigadora del IUMPA, así como las propiedades que inicialmente se pretendía recopilar para cada una de ellas. Esta fase permitió establecer una estructura de referencia para orientar la búsqueda de información y detectar qué datos serían necesarios para construir la base del sistema.

A continuación, se abordó la búsqueda y evaluación de fuentes de datos. El objetivo fue comprobar qué información podía obtenerse a partir de fuentes públicas y accesibles, así como valorar su utilidad para alimentar el modelo planteado. Esta fase incluyó la revisión de fuentes bibliográficas e institucionales, y permitió identificar posibilidades de extracción y limitaciones asociadas a la disponibilidad, completitud y homogeneidad de los datos.

La tercera fase se centró en la construcción progresiva de la base de datos. A partir de la información obtenida, se generaron estructuras tabulares intermedias, se organizaron los datos recopilados y se fueron construyendo las entidades y relaciones necesarias para representar investigadores, revistas, áreas, artículos y proyectos. Esta etapa incluyó también tareas de depuración, homogeneización y validación, especialmente en aquellos casos en los que la información procedente de distintas fuentes requería revisión manual.

Una vez construida una base de datos suficientemente estable, el trabajo avanzó hacia el desarrollo de la aplicación interactiva. En esta fase se diseñaron y construyeron los grafos destinados a representar las relaciones principales del sistema, tanto las derivadas de publicaciones en revistas como las asociadas a proyectos. Además, se incorporaron elementos de interacción que permitieran consultar información asociada a los nodos y explorar la estructura investigadora del instituto de forma más accesible que mediante ficheros estáticos.

Tras completar la parte principal de visualización, se planteó una ampliación analítica orientada a estudiar afinidades temáticas entre investigadores. Esta fase consistió en construir representaciones de los perfiles investigadores a partir de las revistas en las que habían publicado los investigadores, extraer y depurar palabras clave, probar distintas estrategias de agrupación y valorar la utilidad de representaciones semánticas para comparar perfiles investigadores. A diferencia de las fases anteriores, esta etapa tuvo un carácter más experimental, ya que fue necesario comparar enfoques y revisar los resultados obtenidos antes de seleccionar una aproximación final.

Finalmente, la última fase del trabajo se dedicó a la interpretación y valoración de los resultados. En ella se revisó la coherencia de la base de datos construida, la utilidad de los grafos desarrollados y la capacidad del análisis semántico para complementar la información relacional.

CAPÍTULO 4

Construcción de la base de datos

Este capítulo describirá el proceso seguido para construir la base de datos del proyecto a partir de información procedente de distintas fuentes públicas. Se presentarán las fuentes finalmente utilizadas, el procedimiento de extracción y organización inicial de la información, las tareas de depuración, homogeneización y validación realizadas, y la estructura final de las bases de datos empleadas posteriormente en la aplicación interactiva y en el análisis semántico.

4.1 Fuentes de datos

Este apartado describirá las fuentes finalmente utilizadas para recopilar la información del proyecto, como la web del IUMPA, Google Scholar, Scopus, ORCID, Panorama UPV y otras fuentes auxiliares empleadas para completar o contrastar datos. Se explicará qué tipo de información aportó cada fuente, qué papel tuvo dentro del proyecto y qué limitaciones generales presentaba en relación con la disponibilidad, completitud y fiabilidad de los datos.

4.2 Extracción y organización inicial de la información

Este apartado explicará cómo se obtuvo y organizó inicialmente la información procedente de las distintas fuentes. Se describirán los procedimientos empleados, como la recopilación manual, el uso de técnicas de web scraping, la descarga de ficheros o la consulta de plataformas externas, así como la creación de estructuras intermedias para almacenar los datos en formato tabular. El objetivo será mostrar cómo la información dispersa se transformó en un conjunto inicial de datos manejable y preparado para su posterior depuración.

4.3 Depuración, homogeneización y validación de los datos

Este apartado describirá las tareas realizadas para mejorar la calidad y coherencia de la información recopilada. Se tratarán aspectos como la corrección de errores tipográficos, el tratamiento de codificaciones, la homogeneización de nombres de investigadores, firmas y revistas, la resolución de duplicidades, la eliminación de registros erróneos o no relevantes y la validación manual de casos ambiguos. Esta sección permitirá justificar el esfuerzo necesario para convertir datos heterogéneos en una base fiable y explotable.

4.4 Estructura final de las bases de datos

Este apartado presentará la estructura definitiva de las bases de datos construidas durante el proyecto. Se describirán las entidades y relaciones finalmente representadas, los principales ficheros generados, las variables incluidas y la forma en que estas estructuras permiten alimentar tanto la aplicación interactiva como la fase posterior de agrupación semántica. También se señalarán, cuando sea necesario, las diferencias entre el modelo inicialmente planteado y la estructura final obtenida.

4.5 Valoración de la base de datos construida

Este apartado valorará el resultado obtenido tras el proceso de construcción de la base de datos. Se analizará en qué medida la estructura final permite representar de forma coherente la actividad investigadora del IUMPA, qué entidades y relaciones quedan cubiertas y qué utilidad tiene la base como soporte para las fases posteriores del proyecto. También se comentará, de forma sintética, cómo las limitaciones de disponibilidad, calidad y homogeneidad de la información condicionan la interpretación y el uso de la base de datos resultante.

CAPÍTULO 5

Desarrollo de la aplicación interactiva

Este capítulo describirá el desarrollo de la aplicación interactiva construida en R mediante Shiny para explorar la información almacenada en la base de datos. Se explicará la organización general de la herramienta, el proceso de transformación de los datos en grafos interactivos y los elementos de visualización e interacción incorporados para facilitar la consulta de relaciones entre investigadores, publicaciones, revistas y proyectos.

5.1 Diseño general de la herramienta

Este apartado presentará la arquitectura general de la aplicación desarrollada en Shiny. Se explicará cómo se organiza la herramienta, qué papel desempeñan los datos previamente construidos y cómo se estructura la aplicación para permitir la consulta interactiva de la información. También se describirá, de forma general, la relación entre la base de datos, la lógica de procesamiento y los componentes visuales que se muestran al usuario.

5.2 Construcción de los grafos interactivos

Este apartado describirá los diferentes grafos desarrollados para representar la actividad investigadora del IUMPA. Se explicará qué relaciones muestra cada grafo, qué entidades actúan como nodos, qué conexiones se representan mediante aristas y cómo se transforman las bases de datos en estructuras adecuadas para su visualización. También se detallará el papel de los grafos de investigadores, publicaciones, revistas y proyectos dentro de la aplicación.

5.3 Elementos de interacción y visualización

Este apartado recogerá los elementos incorporados para facilitar la exploración de los grafos, como selectores, filtros, paneles informativos, colores, tamaños de nodos y respuestas ante la interacción del usuario. Se explicarán las decisiones de diseño adoptadas para mejorar la legibilidad de las visualizaciones y permitir que el usuario consulte la información de forma intuitiva, dejando la valoración global de la herramienta para el apartado siguiente.

5.4 Valoración de la aplicación desarrollada

Este apartado valorará la utilidad de la aplicación interactiva desarrollada para explorar la información almacenada en la base de datos. Se discutirá en qué medida los grafos permiten representar de forma comprensible las relaciones entre investigadores, publicaciones, revistas y proyectos, y qué aportan los elementos de interacción incorporados frente a una consulta basada únicamente en tablas o ficheros estáticos. También se señalarán las principales limitaciones visuales o funcionales detectadas y posibles mejoras de la herramienta.

CAPÍTULO 6

Agrupación semántica de investigadores

Este capítulo describirá la ampliación analítica del proyecto, orientada a estudiar afinidades temáticas entre investigadores a partir de las revistas en las que han publicado. Para ello, se explicará el proceso de obtención de palabras clave representativas, la construcción de representaciones temáticas de los investigadores y la aplicación de distintos modelos de clustering y reducción de dimensionalidad. El objetivo será mostrar el proceso metodológico seguido hasta obtener una agrupación semántica interpretable.

6.1 Construcción de palabras clave

Este apartado explicará el proceso seguido para obtener palabras clave representativas de las revistas en las que han publicado los investigadores del IUMPA. Se describirá cómo se recopilaron, revisaron y filtraron dichos términos, así como los criterios utilizados para conservar aquellos que resultaban útiles para caracterizar temáticamente las revistas. Esta sección permitirá justificar la base textual sobre la que se construye posteriormente la representación temática de cada investigador.

6.2 Representación temática de los investigadores

Este apartado describirá cómo se transformaron las palabras clave asociadas a las revistas en representaciones analizables de los investigadores. Se explicará la construcción de matrices que relacionan investigadores, revistas y términos temáticos, así como los primeros enfoques basados en coincidencias literales de palabras clave. También se introducirá el cambio hacia representaciones semánticas mediante embeddings, justificando su utilidad para capturar similitudes conceptuales entre perfiles aunque no compartan exactamente los mismos términos.

6.3 Modelos de clustering

Este apartado presentará los distintos modelos de agrupación aplicados sobre las representaciones temáticas construidas. Se describirán las pruebas realizadas con diferentes medidas de distancia, métodos de clustering y técnicas de reducción de dimensionalidad, así como los criterios utilizados para comparar sus resultados. El apartado también recogerá

las dificultades encontradas durante el proceso experimental y las decisiones metodológicas adoptadas para seleccionar las configuraciones más adecuadas.

6.4 Evaluación y discusión de los resultados

Este apartado evaluará los resultados obtenidos en la fase de agrupación semántica de investigadores. Se analizarán las diferencias entre los enfoques probados, la utilidad de las representaciones semánticas frente a las coincidencias literales de palabras clave y la calidad de las agrupaciones obtenidas a partir de métricas cuantitativas y criterios de coherencia temática. También se discutirá hasta qué punto estos resultados complementan la información relacional proporcionada por los grafos y qué limitaciones deben tenerse en cuenta al interpretar los grupos identificados.

CAPÍTULO 7

Conclusiones y trabajo futuro

Este capítulo recogerá las conclusiones generales del trabajo a partir del desarrollo y las valoraciones realizadas en los capítulos anteriores. Se sintetizarán los principales resultados alcanzados en relación con la construcción de la base de datos, el desarrollo de la aplicación interactiva y la agrupación semántica de investigadores, evitando introducir información nueva que no haya sido discutida previamente.

También se valorará el grado de cumplimiento de los objetivos planteados al inicio del trabajo y se destacarán las principales aportaciones del proyecto desde el punto de vista de la ciencia de datos. Finalmente, se señalarán las limitaciones generales que permanecen y se propondrán posibles líneas de trabajo futuro, como la ampliación o actualización de las fuentes de datos, la mejora de la aplicación interactiva y la extensión de la parte analítica.

7.1 Conclusiones generales

Este apartado sintetizará las conclusiones principales del trabajo a partir de los resultados y valoraciones expuestos en los capítulos anteriores. Se recogerá de forma global qué ha aportado la construcción de la base de datos, qué utilidad tiene la aplicación interactiva desarrollada y qué valor añade la agrupación semántica de investigadores. El objetivo será ofrecer una visión conjunta del proyecto, destacando su contribución a la comprensión de la actividad investigadora del IUMPA sin introducir resultados nuevos.

7.2 Cumplimiento de los objetivos

Este apartado revisará los objetivos planteados al inicio de la memoria y valorará en qué medida han sido alcanzados. Se relacionarán los objetivos específicos con las fases desarrolladas durante el proyecto: identificación de entidades y relaciones, recopilación y depuración de datos, construcción de la base de datos, desarrollo de la aplicación interactiva y análisis de afinidades temáticas. Esta sección permitirá cerrar el trabajo de forma coherente, conectando lo propuesto en la introducción con los resultados obtenidos.

7.3 Líneas de trabajo futuro

Este apartado planteará posibles ampliaciones y mejoras del proyecto. Se incluirán líneas como la incorporación de nuevas fuentes de datos, la actualización periódica de la base, la mejora de la aplicación interactiva, la ampliación de las funcionalidades de visualización y el perfeccionamiento de la parte analítica. También se podrán mencionar

posibles extensiones metodológicas, como nuevas formas de representación semántica, métricas adicionales o procedimientos más automatizados de validación y actualización de datos.

Bibliografía

- [1] Newman, M. E. J. *Networks: An Introduction*. Oxford University Press, 2010.
- [2] Manning, C. D., Raghavan, P. y Schütze, H. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [3] Hastie, T., Tibshirani, R. y Friedman, J. *The Elements of Statistical Learning*. Springer, 2009.
- [4] Mikolov, T., Chen, K., Corrado, G. y Dean, J. Efficient Estimation of Word Representations in Vector Space. *arXiv preprint arXiv:1301.3781*, 2013.

APÉNDICE A

Relación del trabajo con los Objetivos de Desarrollo Sostenible

Este anexo recogerá la relación del trabajo con los Objetivos de Desarrollo Sostenible (ODS), de acuerdo con las directrices establecidas por la ETSINF para los Trabajos Fin de Grado. En la versión final de la memoria, aquí deberá incorporarse la justificación de los ODS con los que el proyecto guarda una relación más directa, explicando de qué manera contribuye a ellos y cuál es el alcance real de dicha contribución.

APÉNDICE B

Material complementario

En este anexo podrán incluirse tablas extensas, esquemas auxiliares, detalles técnicos adicionales, capturas ampliadas de la aplicación o cualquier otro material complementario que ayude a entender mejor el trabajo sin sobrecargar el cuerpo principal de la memoria.