

Memoria 25/26

1. Descripción concreta y detallada de las tareas, trabajos desarrollados y departamentos de la entidad a los que he estado asignado

Durante el periodo de prácticas he continuado trabajando en el mismo proyecto de análisis y visualización de datos sobre la actividad investigadora del instituto. El punto de partida era una base de trabajo ya construida durante el curso anterior. En esa primera etapa se había llevado a cabo la recopilación de datos desde distintas fuentes públicas, la limpieza de la información, la estructuración de bases de datos y la construcción de la aplicación web con grafos interactivos. Por ello, en esta nueva fase el objetivo principal ha sido consolidar todo lo realizado, completar las partes pendientes y añadir un bloque analítico final que aportase una visión más profunda sobre las afinidades temáticas entre investigadores.

Iniciando esta etapa final me centré en revisar y adecuar la parte ya construida de la aplicación, dejando definidos correctamente los cuatro grafos principales del proyecto. De este modo, el trabajo ya no consistía sólo en disponer de datos tratados, sino en ofrecer una herramienta funcional en la que poder consultar de forma interactiva las relaciones entre investigadores, sus publicaciones y los proyectos en los que participan. Por tanto, esta parte de cierre transformó lo que antes era una base técnica en una herramienta utilizable.

Una vez asentada esa parte, el trabajo de este curso se centró especialmente en la ampliación analítica del proyecto. La idea principal fue desarrollar un modelo que permitiese agrupar a los investigadores según afinidades temáticas, utilizando para ello las revistas en las que han publicado y las palabras clave más representativas asociadas a dichas revistas. Para comenzar esta fase, recopilé términos característicos de las distintas revistas acudiendo a fuentes como DOAJ, Wikipedia, Scimago o Research.com. Después, fue necesario filtrar esas palabras, decidir umbrales de aparición y construir nuevas bases de datos que relacionasen investigadores, revistas y palabras clave.

A nivel técnico, elaboré varias estructuras de datos para poder trabajar de forma ordenada con esta nueva información. Por una parte, construí una matriz binaria de presencia y ausencia de palabras clave asociadas a cada investigador. Por otra, generé una matriz auxiliar que permitía conservar la relación entre cada palabra y la revista concreta de la que procedía, algo importante para poder interpretar después los resultados del modelo. A partir de ahí, comencé a probar diferentes estrategias de clusterización con el objetivo de detectar grupos de investigadores con intereses o perfiles próximos.

Durante esta fase experimental trabajé con diferentes distancias y métodos de agrupación. Se plantearon alternativas como la distancia euclídea, Manhattan, correlación, Jaccard o coseno, y también se valoró la posibilidad de introducir pasos previos de reducción de dimensionalidad, como PCA o SOM. Asimismo, probé modelos de clustering sobre las matrices binarias y sobre versiones ponderadas de las palabras clave, tratando de dar más peso a los términos representativos y menos a los excesivamente frecuentes o demasiado raros. Para evaluar la calidad de los resultados utilicé medidas como el índice de Silhouette.

Sin embargo, los primeros modelos basados en coincidencias literales entre palabras no ofrecieron una separación suficientemente buena entre grupos. Esta situación hizo

necesario replantear el enfoque y avanzar hacia una representación semántica más rica. Como solución, desarrollé una nueva fase de trabajo basada en word embeddings, utilizando un modelo multilingüe capaz de representar cada palabra en un espacio vectorial continuo. A partir de esos vectores calculé una representación media para cada investigador y, sobre esa nueva base, volví a aplicar distintos métodos de clustering jerárquico. También comparé resultados con y sin reducción de dimensionalidad mediante UMAP, y revisé la influencia de determinadas palabras que distorsionaban la agrupación, como algunos términos geográficos.

La parte final del trabajo consistió en interpretar y comparar los resultados obtenidos. Para ello desarrollé código auxiliar que me permitía transformar los resultados del clustering en tablas y archivos más fáciles de analizar, identificando qué personas quedaban asociadas a cada grupo y qué palabras caracterizaban mejor a cada cluster. Esta etapa fue especialmente relevante porque no solo se trataba de obtener un resultado numérico aceptable, sino de valorar si los grupos generados tenían sentido dentro del contexto real del instituto.

En conjunto, esta segunda etapa de prácticas ha permitido cerrar el proyecto de una forma mucho más completa: por un lado, dejando operativa la parte de visualización interactiva; y por otro, incorporando una línea de análisis temático avanzada que complementa la información relacional que ya mostraban los grafos.

2. Valoración de las tareas desarrolladas con los conocimientos y competencias adquiridas en relación con los estudios universitarios

Las tareas desarrolladas durante este curso me han permitido profundizar en conocimientos que ya había comenzado a aplicar el año anterior, pero también incorporar otros nuevos de mayor complejidad. Si en la primera etapa el trabajo estaba más centrado en la recopilación, limpieza y visualización de datos, en esta segunda fase he podido trabajar de forma más clara con técnicas de análisis multivariante, reducción de dimensionalidad, representación vectorial del lenguaje y evaluación de modelos de agrupación. Esto ha supuesto una ampliación muy importante de las competencias que estaba desarrollando dentro del proyecto.

Desde el punto de vista académico, considero que esta etapa ha sido especialmente valiosa porque me ha permitido entender mejor cómo se pasa de una idea general de análisis a una implementación completa y razonada. De esta forma, para poder aplicar el algoritmo, he tenido que razonar qué variables tiene sentido añadir, cómo estructurar las bases de datos, cómo medir si el resultado es útil y cómo interpretar los grupos obtenidos de forma coherente con la realidad que se estaba estudiando. Esa combinación entre trabajo técnico y reflexión metodológica ha sido, probablemente, uno de los aspectos más enriquecedores de estas prácticas.

Además, he podido reforzar el manejo de herramientas, ya que he seguido trabajando con R en la parte de visualización y despliegue de la aplicación, y con Python en la preparación de datos y en la parte más analítica del proyecto.

3. Relación de los problemas planteados y de los procedimientos seguidos para su resolución

El principal problema de esta segunda fase ha estado en la representación analítica de los datos. Una vez construida la base del proyecto, la dificultad pasó a ser determinar de qué manera podían extraerse afinidades temáticas reales entre investigadores sin caer en agrupaciones artificiales o poco informativas. En un primer momento, el uso directo de palabras clave en formato binario parecía una opción razonable, pero los resultados mostraron que las coincidencias literales eran insuficientes para reflejar relaciones conceptuales más profundas.

Otro problema importante fue decidir qué palabras debían conservarse y cuáles podían introducir ruido. Algunas keywords resultaban demasiado generales y aparecían en casi todos los perfiles, mientras que otras eran tan específicas o aisladas que no ayudaban a definir patrones compartidos. Además, durante la revisión de resultados detecté que ciertas referencias geográficas estaban influyendo negativamente en el clustering, lo que obligó a hacer una nueva depuración de las palabras y a repetir parte del proceso analítico sobre una base más limpia.

Para resolver estas dificultades, primero probé modelos sencillos y medí su rendimiento con indicadores cuantitativos. Cuando comprobé que esos resultados no eran suficientemente satisfactorios, en lugar de forzar conclusiones, volví a formular el problema y pasé a una representación semántica mediante embeddings. Después comparé varias alternativas de agrupación, con y sin reducción de dimensionalidad, y preparé salidas auxiliares que permitieran interpretar mejor los clusters generados. Finalmente, la valoración del modelo no se basó únicamente en una métrica numérica, sino también en la coherencia de los resultados desde el punto de vista temático y del conocimiento experto sobre los investigadores del instituto.

También surgieron pequeñas dificultades relacionadas con la integración final del proyecto, como mantener la coherencia entre las nuevas bases analíticas y la estructura previa de la aplicación, o presentar los resultados de manera comprensible. Estas cuestiones se resolvieron mediante reorganización de los datos, revisión de los ficheros intermedios y elaboración de documentos auxiliares que facilitasen el análisis final.

4. Identificación de las aportaciones que, en materia de aprendizaje, han supuesto las prácticas

Esta etapa de prácticas ha supuesto un aprendizaje especialmente valioso porque me ha permitido cerrar un proyecto largo, ver su evolución completa y afrontar una fase final más abierta e investigadora. He aprendido que, en proyectos reales, muchas veces no existe una única solución correcta desde el principio, sino que es necesario probar enfoques distintos, comparar resultados y aceptar que algunos caminos inicialmente prometedores no terminan siendo los más adecuados.

También he reforzado mi capacidad para analizar críticamente los modelos que utilizo. Una de las lecciones más importantes de este curso ha sido entender que obtener una salida no equivale automáticamente a obtener un resultado útil. Ha sido necesario cuestionar los primeros agrupamientos, revisar las variables empleadas, limpiar de nuevo la información y

buscar representaciones más expresivas. Este proceso me ha ayudado a desarrollar una forma de trabajo más rigurosa y más cercana a lo que implica realmente hacer análisis de datos en un contexto aplicado.

A nivel técnico, quiero destacar lo aprendido en cuanto a la organización avanzada de bases de datos y la creación de matrices específicas para análisis, así como el uso de embeddings semánticos, técnicas de clustering jerárquico, reducción de dimensionalidad e interpretación de resultados.

5. Evaluación de las prácticas y sugerencias de mejora

La valoración global de estas prácticas sigue siendo muy positiva. El hecho de haber podido continuar el mismo proyecto durante un segundo periodo ha sido especialmente enriquecedor, porque me ha permitido no quedarme únicamente en una fase inicial de construcción, sino avanzar hasta una etapa mucho más madura en la que ha sido posible completar, revisar y ampliar el trabajo realizado. Gracias a ello, la experiencia ha sido más completa y formativa que si se hubiese tratado de una práctica breve o desconectada de lo anterior.

Considero que el proyecto ha estado muy bien planteado, tanto por su contenido como por su dificultad progresiva. He podido trabajar con autonomía, tomar decisiones propias y aprender de los errores, pero contando siempre con orientación cuando era necesario. Además, la libertad para explorar distintas soluciones técnicas ha hecho que el aprendizaje fuese más profundo y realista.

Como sugerencia de mejora, considero que habría sido útil disponer desde el inicio de algunas fuentes institucionales más estructuradas, ya que esto habría permitido reducir parte del tiempo invertido en la depuración de datos y en la creación de bases intermedias. No obstante, entiendo que este aspecto escapa en gran medida a las competencias del propio instituto, por lo que no lo considero una carencia relevante.