

3/10/24 → he establecido cuáles pueden ser los nodos y relaciones a estudiar junto con sus propiedades.

10/10/24 → Una vez establecidas y acordados todos los aspectos (nodos, relaciones y propiedades), comienzo a investigar si es realmente posible recopilar información de todas las propiedades propuestas.

Parece que Google Scholar brinda un poco de información. Con la librería *scholar* de R me ahorro el web scraping. [Este blog](#) puede ayudarme a obtener el perfil de los investigadores cuya información esté en este sitio.

15/10/2024 → Me he percatado que necesito saber todos los investigadores internos del IUMPA para saber de quiénes tengo información. He hecho un código de web scraping para obtener dichos nombres

El código de los nombres ha sido sencillo, pero el de los correos no. Algunas personas tenían su página web albergada en `.../nombre-apellido-apellido/`, mientras que otros lo tienen como `.../apellido-apellido-nombre/`, por lo que ha habido que tratar los dos casos.

16/10/2024 → con el objetivo de avanzar más con la construcción de la base de datos, he empleado el código ya comentado el día 10 para recopilar los perfiles de los investigadores. No lo he generalizado aún.

17/10/2024 → Sigo en busca de fuentes de datos. He terminado la plantilla para guardar la información sobre las fuentes de datos y completado los huecos sobre las variables que ya sé de dónde obtener.

A parte de esto, he generalizado algo el código que limpia los excels obtenidos en el Google Scholar, pudiendo ya tener el nombre del artículo publicado por un individuo, su revista y el año de publicación. Además, se puede sacar de esta web, también, los investigadores (tanto internos como externos → para diferenciarlos, compararé los nombres con los nombres obtenidos de la web) con los que cada autor ha publicado un artículo. Cada excel pertenecerá a un solo individuo.

Además, de dicha información de GS se puede obtener información que ayude a definir las relaciones *ha_publicado_con* y *ha_publicado_en*.

Me he fijado, además, en el nodo de "Área". Me he fijado ahora en la variable de "Grupo de investigación" de los investigadores internos. Contaba con poder obtenerla de la página web, pero creo que no va a ser posible porque los botones que modifican la página web no pueden ser accedidos mediante el Web Scraping, por lo que o lo hago a mano, o encuentro otro sitio dónde se pueda obtener esta información.

No tengo muy claro de donde obtener las propiedades de los investigadores internos "Grupo de investigación" y "Tipo de empleado".

23/10/2024 → he esclarecido ideas para saber por dónde seguir apuntándome en un doc a parte las cosas que me faltan y por qué no puedo obtenerlas. Además, he propuesto posibles soluciones a algunos de esos problemas.

17/11/2024 → he intentado generar un código para la obtención de las universidades externas, pero no he sabido cómo acceder a esa información (pese a que se puede ver desde el Google Scholar).

En su defecto, he creado un código genérico que permite la obtención del perfil de los investigadores de Google Scholar de una forma más sencilla y común para todos.

18/11/2024 → día de resolución de dudas. Tras una charla con José Manuel Calabuig, quién está dirigiéndome en el proyecto, veo con más claridad los problemas que había apuntado en el *documento de problemas* previamente creados.

19/11/2024 → tras un asentamiento de ideas con José, hemos cancelado la recolección de los siguientes atributos:

- Tipo de empleado de investigadores internos: al no tener manera de diferenciarlos.
- Grupo de investigación de investigadores internos: por ser demasiado similar a las áreas.
- Los investigadores externos al completo: por considerar, finalmente, que no era algo relevante de estudiar en el contexto del proyecto

Además, los siguientes temas se quedan en *stand by*, a expensas de que José me brinde la información que necesito:

- La parte de proyectos entera: ya que, al ser algo diferente de los artículos, no tengo forma de obtenerlo y él puede intentar conseguirlo.
- Relación ha participado: porque sin la información anterior no puedo actuar sobre esta relación.

A continuación, me he puesto a ordenar el drive, así como a finiquitar la base de datos de los investigadores internos (junto con su código), cerrando así el primero de los nodos.

27/11/2024 → siguiendo con la creación de nodos, y con el objetivo de enfrentarme a la primera relación, me he puesto a copiar (a mano) las diferentes áreas de trabajo de cada uno de las áreas en las que trabajan los diferentes investigadores. Lo he hecho en excel porque el autocompletado facilita la tarea.

10/12/2024 → una vez acabada la información correspondiente a las áreas, he añadido la columnas de los nombres. Además, he convertido los excels a csv para tenerlo todo en el mismo formato.

22/12/2024 → en vista de que solo almacenaré las revistas en las que algún investigador haya trabajado, no veo sensato empezar con ese nodo hasta no obtener toda la información relevante de todos los investigadores internos (con quién ha publicado y en dónde). Esta información, pues, ayudará a terminar el nodo de investigadores internos y las relaciones *ha_publicado_en* y *ha_publicado_con*.

En vista de la diferencia entre estas relaciones, he decidido dividir el csv genérico que creo para cada investigador a partir de la información del Google Scholar en dos (uno para cada tipo de información). Por ende, he debido modificar el código anteriormente creado para que generase directamente los dos csv por separado.

Cabe destacar que, debido a la magnitud de la relación *ha_publicado_en*, he creado un csv diferente para cada individuo. De esta forma, se almacenan las revistas en las que ha publicado cada investigador en un csv. Sin embargo, *ha_publicado_con* mantiene el formato de una fila por individuo al almacenarse los investigadores con los que trabaja en una lista.

23/12/24 - 26/01/25 → este tiempo me he dedicado a:

- Limpiar las bases de datos de los investigadores de artículos erróneos.
- Añadir el acrónimo de cada investigador a la BD de investigadores internos con el objetivo de que funcione como clave ajena al crear el grafo final.
- Generar los datos correctamente para las relaciones *ha_publicado_en* y *ha_publicado_con*.

Cabe destacar que la limpieza de las bases debe tener en cuenta la codificación en la que están (ASCII, UTF-8...). Además, se deben homogeneizar las formas en las que firma una persona.

Uno de los principales problemas con los que me he encontrado es que no todos los investigadores que analizo tienen perfil en Google Scholar, lo que imposibilita encontrar sus artículos de esa forma. De esta forma, he recogido la información de 30/53 investigadores que sí poseían perfil (el resto tendré que determinar una manera para obtener su información).

27/01/25 → he comenzado a trabajar con el nodo revista. Replantando el uso de este nodo, considero que tanto el nombre del artículo como la fecha de su publicación deberían pertenecer a la relación entre el investigador y la revista y no a la revista en sí. De este modo, cambio las propiedades de sitio y prosigo.

La idea final será similar a la de los nodos anteriores (una sola fila para cada nodo de un csv para mantener ordenado el espacio de trabajo).

Para poder obtener esta información correctamente, he creado un código que genera un conjunto con el nombre de todas las revistas de todos los investigadores.

28 - 31/01/2025 → Prosiguiendo con la base de datos de revistas, hoy he acabado de generar el conjunto y me he dedicado a repasar todas las bases de datos que ya tenía para homogeneizar el nombre de las revistas (mayúsculas, minúsculas, acrónimos, etc.).

Para esta homogeneización, he desarrollado un código que, primeramente, genere un diccionario con todas las ocurrencias que se desean igualar. A continuación, se iterará por todos los valores de las columnas que almacenan las revistas (*journal* en *ha_publicado_en*), y se arreglarán todos los csv.

Finalmente, se vuelve a generar el set anterior, pero esta vez con los valores correctos.

Cabe destacar que algunas de las revistas estaban mal definidas o directamente no existían. En esos casos, se han desechado las revistas y se ha asumido que su valor es incorrecto (repitiendo los pasos anteriores de nuevo).

01/02/2025 → Me he dedicado a buscar una solución para obtener la información de los investigadores de los cuáles no he podido obtener información mediante el Google Scholar. Tras poner en práctica algunas ideas, he concluido que mediante Scopus puedo tratar de formatear el resultado y así recopilar los datos que me faltan.

Hoy me he dedicado a familiarizarme y registrarme correctamente con Scopus.

02/02/2025 → Hoy me he dedicado a descargarme todos los csv correctamente. y almacenarlos en su debido lugar con un formato similar a los obtenidos mediante el GS.

Tristemente, Scopus no tiene información de todos los investigadores que me faltaban, pero ha reducido el número de ellos considerablemente.

12/02/2025 → Tras una reunión en la que hemos enfocado lo que faltaba en la base de datos, José me ha comentado la posibilidad de encontrar la información correspondiente a los investigadores que me faltan mediante los enlaces que se pueden encontrar en el directorio de la web de la UPV. Además, hemos actualizado el csv de estos investigadores principales con los nuevos investigadores (y eliminado a aquellos que ya no pertenecen al instituto).

Por otro lado, hemos decidido añadir la relación “investigadores principales” para cuando tengamos los datos de los proyectos.

Por último, y al revisar las revistas, hemos llegado a algunas conclusiones en las que centrarse para mejorar dichos datos. Eso lo trataré de hacer más adelante.

14 - 17/02/2025 → Tras la reunión, primeramente me he puesto a buscar información sobre los investigadores faltantes, mediante los métodos propuestos por José, para poder ubicar a aquellos de los que no se puede obtener información de internet, y poder solicitarla directamente.

18/02/2025 → Uno de los métodos era descargar la información de Orcid. Tristemente, su API posee muchas limitaciones y no es posible obtener toda la información necesaria, por lo que la información de estos investigadores deberá ser solicitada directamente a ellos.

19 - 22/02/2025 → Me he dedicado a obtener los csv correspondientes a los investigadores de los que sí he conseguido información esta vez.

23 - 26/02/2025 → Estos días me he encargado de añadir las nuevas revistas de los investigadores de los que he obtenido información. Además he arreglado algunas de las instancias que ya había (algunas revistas que no tenían sentido, les he dado sentido).

1/03/2025 → Para arreglar los investigadores que tenían asociada una editorial como revista, he desarrollado un código que me avisa de en qué investigadores se hallan estos errores para poder modificarlos manualmente.

2-10/03/2025 → A partir del uso del código desarrollado ayer, he comenzado a arreglar los nodos. El tratamiento ha sido manual.

También me he encargado de quitar las revistas sin editoriales (ya que son erróneas, conferencias o no indexadas). Gracias a la ayuda del ChatGPT he podido saber diferenciar entre los tres tipos de errores que tenían las revistas. El tratamiento ha sido manual.

12/03/2025 → He tenido otra reunión con José Calabuig para comenzar a decidir cómo enfocar la visualización de los datos.

Hemos decidido enfocar las consultas sobre las BBDD a los csv directamente, convirtiendo el resultado en un grafo. El grafo resultante será de: investigadores con los que trabaja el investigador consultado, los artículos de dicho investigador consultado o sus proyectos.

El objetivo de los próximos días es hacer un grafo con echarts y poder acceder a una página web mediante el click de un nodo. Tras esto, trataremos de averiguar si el método pensado para visualizar la consulta es muy tardado o es comprensible.

Sería interesante poder clicar entre diferentes elementos del html resultante, no sólo de páginas webs externas, pero en eso puede que me haga falta más formación.

25 - 27/03/2025 → He dado mis primeros pasos para comprender cómo hacer un grafo con echarts.

Tras muchos intentos, logro conectar una página web con un nodo de uno de los grafos. El objetivo es que, al interactuar con uno de los nodos, este lleve al usuario a otro apartado de la web que se creará. Por ende, un próximo objetivo podría ser que cada nodo haga algo diferente.

9/04/2025 → hoy he tenido reunión con José Calabuig para centrarnos en la representación ya de la web. Hemos quedado que, para estas pascuas, avance con algunas pruebas más avanzadas sobre la realización de los grafos.

Hemos definido que la página web deba tener, principalmente, dos grafos:

- Uno que muestre a los investigadores junto con las publicaciones (revistas) que tienen.
- Otro que muestre a los investigadores junto a otros investigadores para analizar las relaciones entre ellos (quién trabaja con quién).

La idea es que, al clicar un nodo en específico, se muestre a la izquierda el grafo y a la derecha un cuadro de texto con información asociada. Este podría ser un buen punto de inicio.

Esta información será diferente dependiendo de cada nodo:

- En el primer grafo, cuando clickes sobre un investigador debe mostrar, por años, las revistas que este tiene publicadas. Cuando clickes sobre una revista, deberá mostrar quién la ha escrito, dónde está publicada y su editorial.
- En el segundo grafo, cuando clickes sobre un investigador, debe mostrarse una lista del resto de investigadores con los que ha trabajado este individuo.

Cabe destacar que TODOS los investigadores mostrados (y que tengan interacción) serán del IUMPA, obviando a los externos.

Para empezar con este apartado, y siendo que el primer grafo precisa del uso de dos csvs diferentes, he decidido empezar a tantear la segunda opción, que a priori debería ser más sencilla.

11/04/2025 → esta semana santa me he centrado completamente en el segundo grafo.

Para empezar, he tanteado la posibilidad de mostrar un cuadro de texto junto con el grafo al interactuar con un nodo (sin utilizar los datos reales, solo a modo de prueba con datos inventados, para tratar de ver si esto era posible).

13/04/2025 → una vez realizado el paso anterior, paso a intentar otro apartado importante: leer información de uno de los csvs (probaré directamente con el de los investigadores) y plasmarlo en el grafo.

La idea es leer los datos de los csvs necesarios para este apartado (investigadores y con quién han trabajado) y concatenarlos en un inicio. De esta nueva tabla concatenada planeo sacar los nodos (investigadores, que servirán como clave para concatenar) y las aristas (iterando sobre el conjunto de investigadores con los que trabaja cada uno). El problema será que, del conjunto que indica con quién ha trabajado cada investigador, tendrá investigadores externos que deberé tratar (o dejarlos ya que nunca llegarán a iterar sobre ellos).

Este grafo es más simple que el otro debido a que, para unir dos nodos, "sólo" hace falta mirar que uno trabaje con el otro (independientemente de en qué).

Además, al clicar cada investigador, deberá mostrar quiénes son los otros investigadores (del IUMPA, aunque se podría mirar de añadir a los otros con sus acrónimos en otro pequeño apartado) con los que ha trabajado alguna vez.

23/04/2025 → Ya he conseguido una primera versión del grafo en la que se consigue todo lo que se pretendía (un grafo que muestre los investigadores y sus uniones que, al seleccionarlos, muestren los investigadores con los que ha trabajado. Además, se debe poder seleccionar un nodo mediante un selector que filtre el grafo para poder ver su subgrafo propio).

Sin embargo, hay algunos investigadores que no se muestran correctamente (que no se detectan y, por ende, ni se muestran ni se definen sus conexiones). Este será el siguiente punto a investigar y arreglar.

6/05/2025 → Solucionado el problema anterior.

7/05/2025 → Reunión con Jose: hemos matizado el resultado del grafo que tenía ya hecho y definido nuevos objetivos:

- Definir el grafo de revistas para los investigadores, tratando de visualizar, aunque sea vagamente, los artículos en los que ha trabajado cada investigador, o bien las revistas en las que ha publicado un investigador, y que al clicar dicho investigador salga un recuento de sus artículos (y podría hacer que al clicar la revista se vea un resumen de sus artículos publicados).
- Añadir colores (a los 4 grafos) para cada investigador. Cada investigador estará pintado según el área en el que trabaje. Hay que pensar qué hacer con los investigadores que tienen más de un área.
- Cambiar el valor de “Número de conexiones” de inv vs inv. Ahora está puesto el size y quiero poner el número real de conexiones.
- Obtener los proyectos (proyectos competitivos), y otras informaciones, a partir de la página web de panorama para cada investigador.
- A partir de la información anterior, replicar los mismos dos grafos del apartado de las revistas (inv vs inv y publicación vs inv) pero con los proyectos.
- Formatear correctamente lo que aparece en todos los grafos (mensaje de Calabuig 7/5/25), además de darle un formato decente en general a la visualización.
- Hacer un apartado de análisis exploratorio a los datos de cada grafo.

15/05/2025 → He definido el nuevo grafo que representa en qué revistas ha publicado cada investigador, así como sus respectivos artículos (en cada revista). En general, he conseguido definir todo lo propuesto.

29/05/2025 → Tras muchos intentos, no he sido capaz de agrupar los investigadores por áreas de trabajo en ninguno de los dos grafos. Parece ser que la agrupación no permite dividir entre tantos grupos (pese a que en los ejemplos he visto que se pueden definir muchos grupos), aunque igual el problema se basa más en otras cosas como en la obtención de las áreas y su definición como grupo.

Seguiré con las tareas a realizar y volveré a esta en un futuro en caso de que lo veamos necesario.

11/06/2025 → He hecho el arreglo sencillo de ajustar el número de investigadores con los que trabaja cada uno (en Inv. vs. Inv.) y no con el valor de tamaño que le he dado proporcionalmente para que la visualización sea mejor (solucionando el problema de los datos “raros” visualizados al dejar el cursor sobre el nodo).

Para ello, he tenido que “deshacer” el grafo dirigido, ya que el grafo sólo contaba como unión si el propio nodo tenía una unión, y no si esta venía del otro lado. Esto no sería un problema si, al existir una relación entre A y B, al tener que ser simétrica, exista otra entre B y A; pero había un par de casos donde esto no se cumplía, y definir un grafo no dirigido aseguraba que los resultados brindados fueran correctos.

13/06/2025 → He comenzado con la obtención de los proyectos de los investigadores del IUMPA (el último grupo de información que me faltaría). Esta información la intentaré obtener de la web *Panorama* de la UPV (que parece no estar terminada, pero que puede llegar a servir si aparecen la mayoría de los investigadores y la información es verídica y suficiente).

Por lo general, las bases de datos parecen correctas, pero el formato debe ser mejorado:

- Quitar variables que no me interesan → solo quiero Título, autores, fecha,
- Añadir los nombres girados (comenzando por apellido) como “acrónimo” para poder asociar el nombre real a cada uno (en Investigadores_internos).
- Crear una columna que indique si el investigador es principal de ese proyecto.
- Obtener el precio.

27/06/2025 → He definido 3 versiones para representar las áreas en los grafos de revistas:

- Colorear sobre la primera área.
- No colorear pero poder filtrar por área.
- Filtrar por área y colorear por tipo de empleado.

En principio, el resto de puntos están realizados correctamente, exceptuando los proyectos, ya que necesito que Jose me aclare algunas cosas sobre los repetidos y sobre si estos proyectos que he obtenido son los que necesitamos.

31/06/2025 → he realizado un pequeño análisis exploratorio de los datos, para ver qué otras cosas se pueden hacer con la información que tengo hasta el momento. Este punto iría mucho antes en la memoria final.

17/07/2025 → hoy ha habido reunión con Jose y hemos concluido cosas:

Proyectos:

- No elimino los repetidos a menos que se repita título Y año (eso sí es repetido, en otro caso es actualización y debe estar).
- Las redes temáticas se borran.
- Los precios los obviamos
- Espero a ver si nos dan acceso a la BD de la UPV (para ampliar con los que no tienen panorama).

Grafos:

- Me quedo con la v3 (división de becarios, becarios de investigación e investigadores; pudiendo hacer filtro por las áreas).
- Hacer mismos grafos para los proyectos

Ampliación:

- Hacer un modelo que trate de clusterizar a los investigadores. Para ello, saco las keywords de las revistas donde han publicado (revistas, no artículos) (10 por revista) (se lo pido al Chat) → una matriz de one-hot-encoding → filas palabras, columnas revistas: 1 si la revista tiene esa keyword asociada. Me quedo con las más importantes: veo el resultado y pongo un umbral. Asocio a cada investigador las keywords más importantes que aparezcan en las revistas en las que ellos han publicado (todas todas no pq la matriz sería enorme) (podría pensar en más variables para hacer un mejor clustering) (no meto las áreas para que no junte solo por eso) (igual está el problema de que un investigador no tiene palabras pq no se ha cogido ninguna de sus revistas, solo es una posibilidad) → la matriz final será filas personas, columnas palabras? una sola columna que contenga la lista con las palabras? hay que valorarlo. Hago clustering intentado juntar a la gente en función de las keywords más relevantes de las revistas en las que han publicado. La idea puede ser enfocarlos entre si el tipo de revistas en las que publica un individuo hace que estos se asemejen más (perfiles de investigadores más similares → pueden trabajar juntos en nuevos proyectos porque les interesan las mismas ideas).

Para hacer la selección puedo → sumar y coger la más imp // PCA.

Las palabras asociadas a cada investigador deberían ser las 5 (p. e.) más importantes de todas las que tiene.

11/08/2025 → se pueden hacer algunas ampliaciones al grafo de inv vs revistas → un buscador de revistas y añadir las editoriales al clicar sobre una revista. También se podrían añadir las áreas a las que pertenece un determinado investigador (que se muestre al clicar).

Posible ampliación: poner en el grafo conjunto de ha_publicado/participado_con cuál es la revista/el proyecto en común. Haría falta rehacer todo el grafo y sus respectivas BD.

Añadir nº de enlaces al poner el ratón por encima de inv vs proyectos e inv vs revistas. En general, adecentar lo que se muestra.

31/08/2025 → He creado una web con shinyapps.io para subir mis bases de datos y los códigos de los grafos (es decir, todo el grosor del proyecto). Están los 4 grafos definidos correctamente.

05/09/2025 → He comenzado a obtener las palabras más representativas de cada revista para hacer el modelo de clusterización. He accedido a fuentes como DOAJ, Wikipedia, Scimago y Research.com para extraer los términos más frecuentes o destacados de la revista. Me he ayudado de inteligencia artificial para completar estos términos y tener más riqueza, solicitando que me ofrezca nuevas *keywords*.

09/09/2025 → Una vez terminada la obtención de keywords, debo asociar dichas keywords a cada investigador. Para ello, debo filtrar las más importantes quedándome, quizá, con todas aquellas palabras que han aparecido más de una vez.

Una vez establecidas cuáles deben ser las keywords a asociar, debo definir la manera de crear la base de datos donde las asocie a los investigadores. Para ello, puedo juntar a cada uno una lista, sin más, con dichas palabras. Sin embargo, de esta forma pierdo la información de cuál es la revista que le ha aportado dichas palabras al individuo, por lo que creo que también debe estar para enriquecer la información aportada por la clusterización.

10/09/2025 → Ya están filtradas las palabras. No sé muy bien cuál debe ser el mínimo de apariciones. Inicialmente lo he establecido en 10, pero dependiendo de cómo resulte la base de datos con los investigadores + revistas decidiré si aumentar o disminuir el umbral.

También he obtenido la matriz de 0 y 1 que emplearé el modelo de clusterización para realizar los conjuntos de los investigadores. Además, he definido una matriz extra que permite asociar a cada palabra de cada investigador, la revista que se la ha proveído.

16/09/2025 → Hoy he tenido una nueva reunión para asentar los siguientes pasos del proyecto. Hemos definido dos vertientes a partir de las que seguir el proyecto:

- Finalización del apartado de clusterización: una vez obtenidas las bases de datos anteriores, he de definir y trabajar sobre el modelo de clusterización. Debo probar diferentes métodos de distancias y manera de creación de clusters. Algunas son las distancias de: euclídea, mahalanobis, correlación (de Pearson), Manhattan, Jaccard, Hamming, Distancia Coseno.

Por otro lado, se podría aplicar PCA antes del clustering para ver si se obtiene algo mejor.

Si no funcionase el clustering, se podría aplicar el SOM (PCA + clustering), siendo las palabras las que se meten en cada hexágono, y las personas las variables que se representan dentro para indicar las características de cada hexágono.

Una vez obtenido cada modelo, deberé comprobar lo "correcto" de los clusters mediante medidas como la de Silhouette.

- Ampliación del apartado de grafos: convertir los grafos a matrices numéricas (para ello, debo sacar cuántas veces se repite una conexión → que dos personas trabajen juntos) y aplicar

medidas y analíticas propias de grafos (como la centralidad, que luego se puede comparar con los resultados de la clusterización → ver si las más céntricas son importantes en sus respectivos clusters → representantes de sus clusters).

Falta decidir cómo juntar ambas vertientes.

18/09/2025 → He creado el modelo de clustering y he comenzado a probar con valores diferentes para los parámetros buscando los mejores resultados.

El clustering se realizará tratando de juntar a aquellos investigadores con temas o intereses comunes. Para ello, he creado una base de datos que contiene las keywords de las revistas donde cada investigador ha publicado algún artículo. Pretendo hacer un clustering con dichas palabras y los investigadores, juntando a aquellos cuyos vectores sean similares (son OHE con cada columna = persona y fila = palabra).

Los próximos días se basarán en probar este proceso.

20/09/2025 → Tras no obtener buenos resultados con un clustering normal, hemos propuesto dos opciones:

- Clustering con las palabras ponderadas en función de su aparición (poco a muy repetidas y poco repetidas; mucho a repetidas moderadas) → valoro más las que salen normal que las raras y las “mathematics”.
- Clustering tras la aplicación de SOM (reducción de dimensionalidad → hace grupos de palabras → dentro indica la potencia de cada investigador en el grupo de palabras → se pueden clusterizar estos grupos).

28/09/2025 → Otra cosa que podría probar, pese a que precisa rehacer todas las bases de datos, es ver cuántas veces ha escrito cada investigador en cada revista. De esta forma tendría una aproximación más certera sobre los gustos de los investigadores.

Pese a esto, creo que es mejor primero obtener algún resultado con un Silhouette más o menos decente, y luego tratar de hilar más fino.

02/11/2025 → Primeramente, probaré con la ponderación de las keywords por su propio valor de apariciones. Quizá resulte un modelo sencillo en primera instancia, pero voy a probar cuáles son sus resultados y ya me plantearé hacerlo más complejo si no obtengo resultados útiles.

08/11/2025 → Tratando de mejorar la ponderación anteriormente empleada, he decidido utilizar una aproximación algo más compleja, con la que pretendo obtener mejores resultados. Esta nueva manera para aplicar este clustering ponderado va a ser mediante la penalización simétrica (TF-Gaussian weighting), haciendo que los pesos de cada keyword (w_i) se calculen tal que:

$$w_i = e^{-\frac{(f_i - \mu)^2}{2\sigma^2}}, \text{ donde:}$$

- f_i es la frecuencia (número de investigadores o apariciones de la palabra i).
- μ = frecuencia media de las keywords.
- σ = control de la anchura (determina cuánto penalizo los extremos)


Así, las palabras demasiado comunes (p. ej. “science”, “research”) → peso bajo; las palabras extremadamente raras (p. ej. errores o casos únicos) → peso bajo; y las palabras medianamente frecuentes (las que tienen interés porque, en principio, son las que mejor describen los intereses

individuales de cada investigador, y que lo diferencian de los típicos y asemejan a aquellos otros investigadores con gustos similares → los términos “representativos”) → máximo peso.

09/11/2025 → Realmente no hay una relación entre los investigadores en función de sus keywords específicamente. Ninguna de las pruebas, ni con clustering ponderado, se llega a nada concluyente (Silhouette bajo, de máximo 0.3).

No es necesario seguir haciendo pruebas de clustering así, no hay grupos grande (<0.3). Casi todos los investigadores (sus OHE) tienen diferencias bastante grandes. No agarrarse a un clavo ardiendo.

```
hist(as.vector(D), breaks=50, main="Distribución de distancias",  
xlab="Distancia")
```



El siguiente paso lógico cuando el clustering sobre keywords binarias o ponderadas no separa bien es pasar a una representación semántica continua → Clustering semántico mediante embeddings de palabras.

Con el fin de superar las limitaciones del enfoque basado en coincidencias exactas de keywords, se aplicó un modelo de word embeddings que representa cada palabra en un espacio vectorial semántico. Para ello, empleo un modelo multilingüe MiniLM-L12-v2, entrenado sobre corpus en múltiples idiomas. Este modelo transforma cada palabra clave en un vector de 384 dimensiones que captura relaciones de similitud semántica.

A continuación, para cada investigador se calculó el vector promedio de sus keywords, obteniendo así una representación semántica global de su perfil temático. Posteriormente, se calculó la matriz de distancias mediante diferentes distancias, y se aplicaron diferentes métodos de clustering.

Finalmente, se evaluó el número óptimo de grupos mediante el índice de Silhouette, observando que el método agrupa a los investigadores según afinidades conceptuales, incluso cuando las keywords utilizadas difieren en su forma textual.

Este enfoque corresponde a un clustering de embeddings semánticos, donde los grupos se definen por proximidad en el espacio vectorial de significados, en lugar de por coincidencias literales de palabras.

10/11/2025 → Finalmente, los mejores resultados los he obtenido mediante clustering jerárquico de los WE tras aplicar UMAP 0.6 de Silhouette con 3 clusters relativamente grandes. K=4 también da buen resultado, agrupando en un cluster más bajando Silhouette a 0.56.

Me parece que podría quedarme con este resultado, pero igual es buena idea aplicar TF-IDF. Este método permite ponderar las palabras clave en función de su importancia real dentro del conjunto de investigadores: da más peso a aquellas keywords que aparecen en pocos perfiles (indicando especialización) y reduce la influencia de las que son muy comunes (poco discriminativas). Al aplicar TF-IDF, la representación de cada investigador reflejaría mejor su perfil temático distintivo, lo que podría aumentar la separación entre grupos y mejorar la calidad del clustering. En otras palabras, el modelo dejaría de tratar todas las palabras por igual y destacaría las que realmente diferencian unas líneas de investigación de otras.

En la práctica, se aplicaría sobre la matriz binaria de investigadores y palabras clave antes de calcular los embeddings o el clustering. Cada celda de la matriz, que actualmente indica solo presencia (1) o ausencia (0) de una keyword, se reemplazaría por su valor TF-IDF, calculado en función de cuántos investigadores usan esa palabra y cuántas palabras usa cada investigador. De esta forma, las keywords más relevantes para un investigador adquirirían mayor peso en su vector de representación, permitiendo construir embeddings o aplicar clustering sobre una versión más informativa y discriminante de los datos.

12/11/2025 → Hoy ha habido una nueva reunión. Parece que con las cosas que ya están hechas es suficiente, no parece que vaya a ampliar por otro lado. Hacer ampliación de grafo para ver cómo juntas, tomando medidas, es igual que el clustering (redundante) y podría dar cosas diferentes (una de las dos está mal o mala base de datos, no hace falta arriesgarse) → **posibles futuros pasos**.

Lo siguiente va a ser comparar los resultados del clustering de WE con y sin UMAP. El objetivo será sacar las palabras representativas de cada cluster, junto con las personas, para ver si ambos métodos devuelven clusters similares, proporcionales (uno devuelve uno, y el otro devuelve ese uno pero partido en dos) o cosas diferentes.

La cosa va a ser decidir con qué representación me quedo para la memoria final, o si me quedo con ambos y comparo resultados (si salen similares, sino no vale la pena).

En una primera instancia, sin UMAP dice Jose Calabuig que pueden ser clusters sensatos (según sus conocimientos). Menor Silhouette, pero suficientemente bueno (5 clusters) → Por otro lado, con UMAP habría que valorar si comparar 3 o 4 clusters. En principio debe dar igual comparar 5 vs 3/4 porque vamos a valorar sólo sus componentes y palabras representativas (los temas), así que todo bien.

Igualmente, esta última parte debe ser bien explicada en la memoria.

02/12/2025 → En esta reunión, tras decidir que iba a comparar los 5 clusters de No UMAP con los 4 de UMAP, no hemos llegado a ninguna conclusión de con qué modelo quedarme. Sin embargo, al mirar las keywords, nos dimos cuenta que habían muchas keywords de localización que, quizá, están empeorando el modelo de clustering final.

Para subsanar esto, hemos decidido repetir el proceso de clustering (directamente con los word embeddings) eliminando todas aquellas palabras que hacen referencia a lugares geográficos (hemos hecho criba de keywords). De esta forma, esperamos que el clustering sea mejor.

En caso de obtener un mejor clustering, esperamos que la creación de los clusters (lo último que he mirado para el clustering anterior) sea, también, relativamente bueno. En caso de que los clusters se

mantengan malos, habrá que decidir entre alguno de los dos modelos anteriores, pese a las malas keywords. En este último caso, la decisión deberá estar bien fundamentada y no solo basada en números (basarse en el conocimiento de Calabuig para realizar los grupos, y si los realizados tienen sentido → esto también es aplicable a los clusters creados por los nuevos datos).

3/12/2025 → He realizado los modelos de clustering con los nuevos datos. Solo he hecho las pruebas con WE ya que las demás no valía la pena.

14/01/2026 → Tras los exámenes, retomo el trabajo. Hoy solo he analizado los resultados obtenidos por el anterior clustering.

15/01/2026 → Al igual que en el caso anterior, he obtenido las palabras que caracterizan a cada cluster de la nueva tanda de estos.

Los pasos a realizar son:

- Coger los resultados del clustering obtenidos por los códigos de clusterización (el csv de resultados cluster).
- Juntarlo con la matriz de investigadores para saber cuáles son las palabras que representan a cada investigador (se junta con lo anterior).
- Ese resultado se pasa por otro código auxiliar para representar más visualmente los datos en un excel, con una página de excel por cluster y keywords (si hay 5 clusters → 10 páginas, 2 páginas por cluster → para el cluster en sí y otra para las keywords).
- Estos excels finales, más fáciles de tratar mediante código de Python, se representan en matrices para ver si las asignaciones, en este caso, sí son independientes del método y se puede confirmar que existe una razón latente que cree los clusters.

Con esos valores, he comparado la generación de clusters para los métodos de Jerárquico Correlación vs Jerárquico Coseno vs Jerárquico Coseno UMAP (mejores Silhouette). Los resultados obtenidos se encuentran en su respectivo documento.